

VIETNAM NATIONAL UNIVERSITY HO CHI MINH CITY
HO CHI MINH CITY UNIVERSITY OF SCIENCE
FACULTY OF INFORMATION TECHNOLOGY



DEPARTMENT OF COMPUTER SCIENCE

REPORT OF PROJECT 1

Project: Ma Trận và Cơ Sở Tính Toán của Khoa Học

Lecturer:	ThS. Võ Nam Thực Đoàn	
	ThS. Lê Nhật Nam	
Leader:	Khang Phúc Nguyễn	24120068
Members:	Nghia Trong Hoàng	24120103
	Nhat Hoang Mai	24120109
	Nhat Hoang Nguyễn	24120110
	Long Nhat Phung Vo	24120088

Ho Chi Minh City, 4/2026

Table of Contents

1	Phép khử Gauss và các ứng dụng	2
1.1	Đặt Vấn Đề	2
1.2	Cơ Sở Lý Thuyết	2
1.2.1	Ma trận tăng cường và các phép biến đổi dòng sơ cấp	2
1.2.2	Dạng bậc thang dòng (REF) và dạng rút gọn (RREF)	3
1.2.3	Phân loại nghiệm	3
1.2.4	Khử Gauss có chọn phần tử chốt (Partial Pivoting)	3
1.3	Thuật Toán Khử Gauss Với Partial Pivoting	4
1.4	Các Ứng Dụng Cài Đặt	5
1.4.1	Giải hệ tam giác trên (Back Substitution)	5
1.4.2	Tính định thức qua khử Gauss	6
1.4.3	Tìm ma trận nghịch đảo bằng Gauss–Jordan	6
1.4.4	Hạng ma trận và cơ sở các không gian con	7
1.5	Tổng Kết	7
2	Phân Rã Ma Trận và Trực Quan Hóa với Manim	9
2.1	Chéo Hóa Ma Trận Matrix Diagonalization	9
2.1.1	Cơ Sở Lý Thuyết	9
2.1.1.a	Giá Trị Riêng và Vectơ Riêng	9
2.1.1.b	Định Nghĩa và Điều Kiện Chéo Hóa	9
2.1.2	Ý Nghĩa Hình Học	10
2.1.3	Thuật Toán Chéo Hóa	11
2.1.4	Ứng Dụng: Tính Lũy Thừa Ma Trận	12
2.2	Phân Rã Giá Trị Kỳ Dị Singular Value Decomposition	13
2.2.1	Giới Thiệu và Đặt Vấn Đề	13
2.2.2	Bối Cảnh và Động Lực	13
2.2.3	Vấn Đề Cần Giải Quyết	14
2.2.4	Cơ Sở Lý Thuyết	14
2.2.5	Ma Trận Trực Giao và Tính Chất	14
2.2.6	Ma Trận Đối Xứng Xác Định Không Âm	15
2.2.7	Định Nghĩa Giá Trị Kỳ Dị	15
2.2.8	Phân Rã Giá Trị Kỳ Dị — Định Lý và Chứng Minh	16



2.2.9	Phát Biểu Định Lý	16
2.2.10	Chứng Minh Định Lý	16
2.2.11	Tính Chất Hình Học của SVD	18
2.2.12	SVD = Quay – Co Giãn – Quay	18
2.2.13	Hình Ảnh của Hình Cầu Đơn Vị	18
2.2.14	Tính Chất Đại Số	19
2.2.15	Rank và Các Không Gian Con	19
2.2.16	Chuẩn Ma Trận	19
2.2.17	Dạng Tích Ngoài (Outer Product Form)	20
2.2.18	Giả Nghịch Đảo Moore–Penrose	20
2.2.19	Ứng Dụng	21
2.2.20	Xấp Xỉ Hạng Thấp — Định Lý Eckart–Young	21
	2.2.20.a Định Nghĩa Xấp Xỉ Hạng k	21
	2.2.20.b Định Lý Eckart–Young–Mirsky	21
2.2.21	Giải Hệ Bình Phương Tối Thiểu qua SVD	23
2.2.22	Phân Tích Thành Phần Chính (PCA)	24
2.2.23	Kết Luận	24
2.3	Phân rã QR QR Decomposition	25
2.3.1	Giới Thiệu và Đặt Vấn Đề	25
2.3.2	Bối cảnh và Động lực	25
2.3.3	Vấn đề Cần Giải Quyết	25
2.3.4	Cơ Sở Lý Thuyết	26
2.3.5	Không gian Vectơ và Tích trong	26
2.3.6	Phép Chiếu Trực Giao	27
2.3.7	Ma Trận Trực Giao	27
2.3.8	Tồn Tại và Duy Nhất của Phân Rã QR	28
2.3.9	Phương Pháp Gram–Schmidt	29
2.3.10	Ý Tưởng Cơ Bản	29
2.3.11	Gram–Schmidt Cổ Điển (CGS)	29
	2.3.11.a Liên hệ với Ma trận $\mathbf{R}$	30
2.3.12	Gram–Schmidt Chỉnh Hóa (MGS)	31
	2.3.12.a So Sánh CGS và MGS	31
2.3.13	Phương Pháp Phản Xạ Householder	32



2.3.14	Ma Trận Householder	32
2.3.15	Xây Dựng Vectơ Householder	33
2.3.16	Thuật Toán Phân Rã QR bằng Householder	33
2.3.17	Tính Ổn Định Số	34
2.3.18	Tính Trục Giao Của $\hat{\mathbf{Q}}$	34
2.3.19	Ứng Dụng: Bài Toán Bình Phương Tối Thiểu	34
2.3.20	Đặt Vấn Đề	34
2.3.21	Giải Qua Phân Rã QR	35
2.3.22	Quy Trình Giải Trên Thực Tế	36
2.3.23	Ứng Dụng: Thuật Toán QR Tìm Giá Trị Riêng	36
2.3.24	Kết Luận	37
3	Phân tích ổn định với hai loại ma trận	39
3.1	Cơ Sở Lý Thuyết Về Ổn Định Số	39
3.2	Các Phương Pháp Giải Tích Hợp và Cài Đặt	40
3.3	Phân Tích Độ Phức Tạp Thời Gian (Time Complexity Analysis)	40
3.4	Kết Quả Thực Nghiệm Ổn Định Số	42
3.5	Phân Tích Đánh Giá Trên Ma Trận Hilbert (Ill-conditioned)	43
3.5.1	Cơ Sở Toán Học và Đặc Điểm	43
3.5.2	Hiện tượng diễn hình trên ma trận Hilbert	44
3.5.3	Phân Tích Độ Tin Cậy Của Các Thuật Toán	45
3.6	Phân Tích Đánh Giá Trên Ma Trận Ngẫu Nhiên SPD (Well-conditioned)	46
3.6.1	Cơ Sở Toán Học và Đặc Điểm	46
3.6.2	Phân Tích Độ Tin Cậy và Hiệu Năng Của Các Thuật Toán	46
3.7	Tổng Kết Sự So Sánh	47
3.8	Phân Tích và Kết Luận	47
3.9	Kết Luận	48
4	Kết Luận và Bài Học	50
4.1	Tổng Kết Đồ Án	50
4.2	Những Khó Khăn Gặp Phải	50
4.3	Bài Học Rút Ra	51
5	Phân Công Công Việc	52



Video Demo Trực Quan

Toàn bộ video trình bày thuật toán bằng thư viện **Manim** (Bao gồm giới thiệu nhóm và mô phỏng QR, SVD, Chéo hóa) đã được nhóm biên dịch và đăng tải lên YouTube.

Mời thầy cô xem tại đường dẫn sau: <https://youtu.be/-fa9aWKXBOY>.

1 Phép khử Gauss và các ứng dụng

1.1 Đặt Vấn Đề

Bài toán trung tâm và có tầm quan trọng bậc nhất trong đại số tuyến tính là giải hệ phương trình tuyến tính $\mathbf{Ax} = \mathbf{b}$, trong đó $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{x} \in \mathbb{R}^n$ và $\mathbf{b} \in \mathbb{R}^m$. Từ bài toán nền tảng này phát sinh hàng loạt các bài toán phái sinh quan trọng khác: tính định thức $\det(\mathbf{A})$, tìm ma trận nghịch đảo $\mathbf{A}^{-1}$, xác định hạng $\text{rank}(\mathbf{A})$, và khảo sát cấu trúc các không gian con cơ bản như không gian cột $C(\mathbf{A})$, không gian dòng $R(\mathbf{A})$, và không gian nghiệm $N(\mathbf{A})$ [1].

Trong lịch sử phát triển của đại số tuyến tính tính toán, phép khử Gauss và phép khử Gauss–Jordan được xem là hai công cụ nền tảng nhất để tiếp cận toàn bộ nhóm bài toán kể trên. Ý tưởng cốt lõi của chúng — sử dụng các phép biến đổi dòng sơ cấp để đưa ma trận hệ số về các dạng chuẩn — đã được phát triển và hoàn thiện qua nhiều thế kỷ, từ các công trình của C.F. Gauss (thế kỷ 19) cho đến các phân tích ổn định số học của J.H. Wilkinson vào thế kỷ 20 [2, 3]. Khi triển khai trên máy tính với hệ số dấu phẩy động, vấn đề chọn phần tử chốt (*pivoting*) trở nên then chốt để kiểm soát sai số tích lũy — một nhận thức đã dẫn đến sự ra đời của kỹ thuật *partial pivoting* mà ngày nay được coi là chuẩn mực trong mọi cài đặt thực tế [3].

1.2 Cơ Sở Lý Thuyết

1.2.1 Ma trận tăng cường và các phép biến đổi dòng sơ cấp

Hệ phương trình $\mathbf{Ax} = \mathbf{b}$ có thể được biểu diễn một cách gọn gàng bằng **ma trận tăng cường** (*augmented matrix*) [1]:

$$[\mathbf{A} \mid \mathbf{b}] = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} & b_1 \\ a_{21} & a_{22} & \cdots & a_{2n} & b_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} & b_m \end{pmatrix}. \quad (1)$$

Mọi thao tác trên hệ phương trình được thực hiện thông qua ba phép biến đổi dòng sơ cấp, vốn không làm thay đổi tập nghiệm của hệ. Phép thứ nhất là **hoán đổi hai dòng**: $R_i \leftrightarrow R_j$. Phép thứ hai là **nhân một dòng với hằng số khác không**: $R_i \leftarrow c R_i$ với $c \neq 0$. Phép thứ ba là **cộng bội của một dòng vào dòng khác**: $R_i \leftarrow R_i + c R_j$. Tính hợp lệ của ba phép biến

đổi này bắt nguồn từ thực tế rằng mỗi phép tương ứng với phép nhân bên trái ma trận tăng cường bởi một **ma trận sơ cấp** khả nghịch, do đó bảo toàn hoàn toàn tập nghiệm [2].

1.2.2 Dạng bậc thang dòng (REF) và dạng rút gọn (RREF)

Định nghĩa 1.1: Dạng bậc thang dòng (Row Echelon Form — REF)

Ma trận $\mathbf{U}$ được gọi là ở dạng bậc thang dòng nếu thỏa mãn đồng thời hai điều kiện: (i) tất cả các dòng toàn số 0 nằm phía dưới cùng của ma trận, và (ii) phần tử khác 0 đầu tiên (**pivot**) của mỗi dòng khác 0 nằm bên phải pivot của dòng ngay phía trên.

Định nghĩa 1.2: Dạng bậc thang dòng rút gọn (Reduced REF — RREF)

Ma trận $\mathbf{R}$ ở dạng RREF nếu ngoài việc thỏa mãn REF, còn thỏa thêm hai điều kiện: (i) mỗi pivot bằng 1, và (ii) trong mỗi cột chứa pivot, tất cả các phần tử còn lại đều bằng 0.

Phép khử Gauss sử dụng các phép biến đổi dòng sơ cấp để đưa ma trận về dạng REF, sau đó dùng quá trình thế ngược (*back substitution*) để tìm nghiệm. Phép khử Gauss-Jordan tiếp tục biến đổi từ REF sang RREF, cho phép đọc nghiệm trực tiếp từ ma trận kết quả mà không cần thế ngược. Cả hai dạng đều là công cụ quan trọng trong phân tích cấu trúc của hệ phương trình [1].

1.2.3 Phân loại nghiệm

Sau khi đưa ma trận tăng cường $[\mathbf{A} \mid \mathbf{b}]$ về dạng REF hoặc RREF, hệ phương trình được phân loại thành ba trường hợp dựa trên cấu trúc pivot [1]. Nếu xuất hiện dòng có dạng $[0 \ 0 \ \cdots \ 0 \mid c]$ với $c \neq 0$, hệ **vô nghiệm** vì ta thu được phương trình mâu thuẫn $0 = c$. Nếu không có mâu thuẫn và số pivot bằng đúng số ẩn n , mỗi biến đều là biến pivot và hệ có **nghiệm duy nhất**. Trường hợp còn lại, khi số pivot nhỏ hơn n , các biến không tương ứng với pivot trở thành **biến tự do**, và hệ có **vô số nghiệm** được tham số hóa theo các biến tự do đó.

1.2.4 Khử Gauss có chọn phần tử chốt (Partial Pivoting)

Trong tính toán dấu phẩy động, phép chia cho một pivot có giá trị tuyệt đối rất nhỏ sẽ khuếch đại sai số làm tròn một cách nghiêm trọng. Để khắc phục vấn đề này, kỹ thuật *partial pivoting* được áp dụng: tại mỗi bước khử thứ k , ta chọn dòng p sao cho phần tử chốt có trị tuyệt đối lớn

nhất trong phần cột còn lại [3]:

$$|a_{pk}^{(k)}| = \max_{k \leq i \leq m} |a_{ik}^{(k)}|. \quad (2)$$

Sau đó, dòng k và dòng p được hoán đổi trước khi tiến hành khử. Kỹ thuật này đảm bảo rằng tất cả các hệ số nhân (*multipliers*) $\ell_{ik} = a_{ik}^{(k)} / a_{kk}^{(k)}$ thỏa $|\ell_{ik}| \leq 1$, giúp hạn chế sự phát triển của sai số. Theo phân tích của Wilkinson, phép khử Gauss với partial pivoting đảm bảo **ổn định ngược** (*backward stability*) trong hầu hết các trường hợp thực tế [3, 4]. Trong cài đặt, một ngưỡng nhỏ ε (ví dụ 10^{-12}) thường được sử dụng để phát hiện các pivot gần bằng 0, từ đó cảnh báo hệ thống có thể **kém điều kiện** (*ill-conditioned*).

Partial pivoting không chỉ là một kỹ thuật tối ưu hóa mà là điều kiện tiên quyết cho tính đúng đắn số học của phép khử Gauss khi triển khai trên máy tính. Thiếu pivoting, ngay cả các hệ phương trình nhỏ cũng có thể cho kết quả hoàn toàn sai lệch do hiện tượng tích lũy sai số [5].

1.3 Thuật Toán Khử Gauss Với Partial Pivoting

Phần này mô tả chi tiết thuật toán khử Gauss có chọn phần tử chốt — nền tảng cho tất cả các thao tác tính toán trong Phần 1 của đề án.

Thuật toán: Khử Gauss với Partial Pivoting

Đầu vào: Ma trận $\mathbf{A} \in \mathbb{R}^{m \times n}$, vectơ $\mathbf{b} \in \mathbb{R}^m$.

Đầu ra: Ma trận tam giác trên $\mathbf{U}$, vectơ biến đổi $\mathbf{c}$, số lần hoán đổi dòng s , danh sách chỉ số cột pivot.

Các bước:

1. Lập ma trận tăng cường $\mathbf{M} = [\mathbf{A} \mid \mathbf{b}]$, đặt $s = 0$.
2. Với mỗi cột $k = 1, 2, \dots, \min(m, n)$:
 - (a) Tìm dòng p sao cho $|M_{pk}| = \max_{k \leq i \leq m} |M_{ik}|$.
 - (b) Nếu $|M_{pk}| < \varepsilon$: cột k không có pivot, chuyển sang cột tiếp theo.
 - (c) Nếu $p \neq k$: hoán đổi $R_k \leftrightarrow R_p$, tăng $s \leftarrow s + 1$.
 - (d) Với mỗi dòng $i = k + 1, \dots, m$: tính $\ell_{ik} = M_{ik}/M_{kk}$ và cập nhật

$$M_{i,\cdot} \leftarrow M_{i,\cdot} - \ell_{ik} M_{k,\cdot} \quad (3)$$

3. Tách $\mathbf{U}$ và $\mathbf{c}$ từ $\mathbf{M}$.

Độ phức tạp. Khử Gauss cho ma trận vuông $n \times n$ có độ phức tạp thời gian $\mathcal{O}(\frac{2}{3}n^3)$ cho giai đoạn khử và $\mathcal{O}(n^2)$ cho giai đoạn thế ngược, tổng cộng $\mathcal{O}(n^3)$ [2]. Đây là phương pháp phù hợp cho các hệ phương trình có kích thước vừa phải và là nền tảng cho nhiều phương pháp phân rã nâng cao như LU, QR, hay SVD.

1.4 Các Ứng Dụng Cài Đặt

1.4.1 Giải hệ tam giác trên (Back Substitution)

Sau khi khử Gauss đưa hệ phương trình về dạng tam giác trên $\mathbf{U}\mathbf{x} = \mathbf{c}$, quá trình **thế ngược** (*back substitution*) giải hệ bằng cách tính lần lượt các thành phần x_i từ dưới lên [2]. Phương trình cuối cùng cho ta $u_{nn}x_n = c_n$, từ đó $x_n = c_n/u_{nn}$. Các thành phần còn lại được tính theo công thức đệ quy:

$$x_i = \frac{1}{u_{ii}} \left(c_i - \sum_{j=i+1}^n u_{ij} x_j \right), \quad i = n-1, n-2, \dots, 1. \quad (4)$$

Trong quá trình thế ngược, cần xử lý ba trường hợp riêng biệt. Nếu $u_{ii} \neq 0$ cho mọi i , hệ có

nghiệm duy nhất và công thức (4) áp dụng trực tiếp. Nếu $u_{ii} = 0$ nhưng $c_i \neq 0$, phương trình thứ i trở thành $0 = c_i$ (mâu thuẫn), hệ **vô nghiệm**. Nếu $u_{ii} = 0$ và $c_i = 0$, biến x_i trở thành **biến tự do** và hệ có **vô số nghiệm**; nghiệm tổng quát được biểu diễn dưới dạng tổ hợp tuyến tính của các vectơ cơ sở ứng với từng biến tự do.

1.4.2 Tính định thức qua khử Gauss

Định thức của ma trận vuông $\mathbf{A} \in \mathbb{R}^{n \times n}$ có thể được tính hiệu quả thông qua phép khử Gauss. Sau khi đưa $\mathbf{A}$ về dạng tam giác trên $\mathbf{U}$ với s lần hoán đổi dòng, ta có [1]:

$$\det(\mathbf{A}) = (-1)^s \prod_{i=1}^n u_{ii}. \quad (5)$$

Công thức này dựa trên ba tính chất quan trọng. Thứ nhất, phép cộng bội dòng (thao tác chính trong khử Gauss) **không làm thay đổi** giá trị định thức. Thứ hai, mỗi phép hoán đổi dòng **đổi dấu** định thức, nên sau s lần hoán đổi ta nhân thêm hệ số $(-1)^s$. Thứ ba, định thức của ma trận tam giác bằng **tích các phần tử đường chéo chính** [2].

Phương pháp này có độ phức tạp $\mathcal{O}(n^3)$, hiệu quả hơn rất nhiều so với công thức khai triển Laplace truyền thống có độ phức tạp $\mathcal{O}(n!)$ [1]. Nếu trong quá trình khử không thể tìm được pivot khác 0 cho một cột nào đó, kết luận ngay rằng $\det(\mathbf{A}) = 0$ — ma trận suy biến.

1.4.3 Tìm ma trận nghịch đảo bằng Gauss–Jordan

Ma trận vuông $\mathbf{A} \in \mathbb{R}^{n \times n}$ khả nghịch khi và chỉ khi $\det(\mathbf{A}) \neq 0$. Phương pháp Gauss–Jordan tìm $\mathbf{A}^{-1}$ bằng cách ghép $\mathbf{A}$ với ma trận đơn vị $\mathbf{I}_n$ và áp dụng các phép biến đổi dòng cho đến khi vế trái trở thành $\mathbf{I}_n$ [1]:

$$[\mathbf{A} \mid \mathbf{I}_n] \xrightarrow{\text{Gauss-Jordan}} [\mathbf{I}_n \mid \mathbf{A}^{-1}]. \quad (6)$$

Về mặt đại số, mỗi phép biến đổi dòng tương ứng với phép nhân bên trái bởi một ma trận sơ cấp $\mathbf{E}_k$. Nếu chuỗi biến đổi đưa $\mathbf{A}$ về $\mathbf{I}_n$, ta có $\mathbf{E}_t \cdots \mathbf{E}_2 \mathbf{E}_1 \mathbf{A} = \mathbf{I}_n$, suy ra $\mathbf{A}^{-1} = \mathbf{E}_t \cdots \mathbf{E}_2 \mathbf{E}_1$. Khối bên phải của ma trận ghép tích lũy chính xác tích này, và do đó chứa ma trận nghịch đảo [2].

Quy trình cài đặt bao gồm ba thao tác lặp lại cho mỗi cột: chọn pivot và hoán đổi dòng (nếu cần), chuẩn hóa dòng pivot về 1 bằng cách chia cho giá trị pivot, sau đó khử toàn bộ các phần tử khác trong cột pivot (cả phía trên và phía dưới) để đạt RREF. Nếu tại bước nào đó không

thể tìm được pivot khác 0, kết luận rằng $\mathbf{A}$ suy biến và không có nghịch đảo.

1.4.4 Hạng ma trận và cơ sở các không gian con

Định nghĩa 1.3: Hạng ma trận

Hạng của ma trận $\mathbf{A}$, ký hiệu $\text{rank}(\mathbf{A})$, bằng số cột pivot trong dạng REF hoặc RREF của $\mathbf{A}$. Giá trị này đồng thời bằng số chiều của không gian cột $C(\mathbf{A})$, của không gian dòng $R(\mathbf{A})$, và thỏa mãn định lý hạng-nullity: $\text{rank}(\mathbf{A}) + \dim N(\mathbf{A}) = n$ [1].

Sau khi đưa ma trận $\mathbf{A}$ về dạng RREF, ba không gian con cơ bản được trích xuất như sau.

Không gian cột $C(\mathbf{A})$ được sinh bởi các **cột pivot của ma trận gốc $\mathbf{A}$** (chứ không phải từ RREF). Lý do là phép biến đổi dòng bảo toàn quan hệ phụ thuộc tuyến tính giữa các cột, nhưng thay đổi giá trị cụ thể của chúng; do đó các cột tương ứng trong $\mathbf{A}$ gốc mới tạo thành cơ sở đúng cho $C(\mathbf{A})$ [1].

Không gian dòng $R(\mathbf{A})$ được sinh bởi các **dòng khác 0 trong RREF**. Khác với không gian cột, phép biến đổi dòng bảo toàn không gian dòng, nên các dòng khác 0 của RREF trực tiếp tạo thành cơ sở cho $R(\mathbf{A})$.

Không gian nghiệm $N(\mathbf{A})$ (còn gọi là *null space*) là tập nghiệm của hệ thuần nhất $\mathbf{Ax} = \mathbf{0}$. Từ RREF, ta nhận diện tập chỉ số biến tự do F . Mỗi biến pivot x_p được biểu diễn theo các biến tự do [1]:

$$x_p = - \sum_{j \in F} r_{pj} x_j, \quad (7)$$

trong đó r_{pj} là phần tử tương ứng trong RREF. Lần lượt đặt mỗi biến tự do x_k bằng 1 (các biến tự do khác bằng 0), ta thu được một vectơ nghiệm cơ sở. Tập hợp các vectơ này tạo thành cơ sở cho $N(\mathbf{A})$, với số chiều bằng $n - \text{rank}(\mathbf{A})$.

1.5 Tổng Kết

Bảng 1 tóm tắt tất cả các thao tác tính toán trong Phần 1 cùng cơ sở toán học và độ phức tạp tương ứng.



Table 1: Tổng hợp các bài toán và phương pháp giải trong Phần 1

Bài toán	Phương pháp	Độ phức tạp	Kỹ thuật hỗ trợ
Giải hệ $\mathbf{Ax} = \mathbf{b}$	Khử Gauss + thế ngược	$\mathcal{O}(n^3)$	Partial pivoting
Tính $\det(\mathbf{A})$	Khử Gauss $\rightarrow$ tích đường chéo	$\mathcal{O}(n^3)$	Đếm hoán đổi dòng chéo
Tìm $\mathbf{A}^{-1}$	Gauss–Jordan trên $[\mathbf{A} \mid \mathbf{I}]$	$\mathcal{O}(n^3)$	RREF + pivoting
$\text{rank}(\mathbf{A})$ và cơ sở	Đưa về RREF	$\mathcal{O}(mn^2)$	Trích pivot/biến tự do

Phép khử Gauss với partial pivoting đóng vai trò nền tảng cho toàn bộ nhóm bài toán trong Phần 1. Từ một quy trình khử duy nhất, ta có thể đồng thời giải hệ phương trình, tính định thức, kiểm tra tính khả nghịch, và phân tích cấu trúc không gian con của ma trận — thể hiện sức mạnh thống nhất của phương pháp. Các phần tiếp theo của đề án (Phần 2: phân rã QR và SVD, Phần 3: phân tích ổn định số) sẽ xây dựng trên nền tảng này để mở rộng sang các bài toán phức tạp hơn.

2 Phân Rã Ma Trận và Trục Quan Hóa với Manim

2.1 Chéo Hóa Ma Trận Matrix Diagonalization

2.1.1 Cơ Sở Lý Thuyết

2.1.1.a Giá Trị Riêng và Vectơ Riêng

Định nghĩa 2.1: Giá trị riêng và Vectơ riêng

Cho ma trận vuông $\mathbf{A} \in \mathbb{R}^{n \times n}$. Một số vô hướng $\lambda \in \mathbb{C}$ được gọi là **giá trị riêng** (*eigenvalue*) của $\mathbf{A}$ nếu tồn tại một vectơ khác không $\mathbf{v} \in \mathbb{C}^n$ sao cho:

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v} \quad (8)$$

Khi đó, $\mathbf{v}$ được gọi là **vectơ riêng** (*eigenvector*) của $\mathbf{A}$ ứng với giá trị riêng λ .

Phương trình (8) có thể được viết lại dưới dạng thuần nhất: $(\mathbf{A} - \lambda\mathbf{I})\mathbf{v} = \mathbf{0}$. Để hệ này có nghiệm $\mathbf{v} \neq \mathbf{0}$, ma trận hệ số phải suy biến, tức là:

$$\det(\mathbf{A} - \lambda\mathbf{I}) = 0 \quad (9)$$

Đây được gọi là **phương trình đặc trưng** của ma trận $\mathbf{A}$. Khai triển định thức này, ta thu được một đa thức bậc n theo λ , gọi là đa thức đặc trưng $p(\lambda)$. Các nghiệm của $p(\lambda) = 0$ chính là các giá trị riêng của $\mathbf{A}$.

2.1.1.b Định Nghĩa và Điều Kiện Chéo Hóa

Định nghĩa 2.2: Ma trận chéo hóa được

Ma trận $\mathbf{A} \in \mathbb{R}^{n \times n}$ được gọi là **chéo hóa được** (*diagonalizable*) nếu tồn tại một ma trận khả nghịch $\mathbf{P} \in \mathbb{C}^{n \times n}$ và một ma trận đường chéo $\mathbf{D} \in \mathbb{C}^{n \times n}$ sao cho:

$$\mathbf{A} = \mathbf{P}\mathbf{D}\mathbf{P}^{-1} \quad \text{hay} \quad \mathbf{P}^{-1}\mathbf{A}\mathbf{P} = \mathbf{D} \quad (10)$$

Định lý 2.1: Điều kiện cần và đủ để chéo hóa

Ma trận $\mathbf{A} \in \mathbb{R}^{n \times n}$ chéo hóa được khi và chỉ khi nó có đúng n vectơ riêng độc lập tuyến tính.

Chứng minh. Giả sử $\mathbf{A}$ có n vectơ riêng độc lập tuyến tính $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ ứng với các giá trị riêng $\lambda_1, \lambda_2, \dots, \lambda_n$. Đặt $\mathbf{P} = [\mathbf{v}_1 \mid \mathbf{v}_2 \mid \dots \mid \mathbf{v}_n]$. Vì các cột của $\mathbf{P}$ độc lập tuyến tính nên $\mathbf{P}$ khả nghịch. Ta xét tích $\mathbf{AP}$:

$$\begin{aligned}\mathbf{AP} &= \mathbf{A}[\mathbf{v}_1 \mid \mathbf{v}_2 \mid \dots \mid \mathbf{v}_n] \\ &= [\mathbf{A}\mathbf{v}_1 \mid \mathbf{A}\mathbf{v}_2 \mid \dots \mid \mathbf{A}\mathbf{v}_n] \\ &= [\lambda_1\mathbf{v}_1 \mid \lambda_2\mathbf{v}_2 \mid \dots \mid \lambda_n\mathbf{v}_n] \\ &= [\mathbf{v}_1 \mid \mathbf{v}_2 \mid \dots \mid \mathbf{v}_n] \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{pmatrix} \\ &= \mathbf{PD}\end{aligned}$$

Nhân hai vế với $\mathbf{P}^{-1}$ từ bên phải, ta thu được $\mathbf{A} = \mathbf{PDP}^{-1}$. Quá trình ngược lại cũng dễ dàng chứng minh. $\square$

Một hệ quả quan trọng là nếu $\mathbf{A}$ có n giá trị riêng *phân biệt*, thì các vectơ riêng tương ứng với chúng chắc chắn độc lập tuyến tính, do đó $\mathbf{A}$ luôn chéo hóa được [1].

2.1.2 Ý Nghĩa Hình Học

Về mặt hình học, việc nhân một vectơ $\mathbf{x}$ với ma trận $\mathbf{A}$ thể hiện một phép biến đổi tuyến tính. Phép biến đổi này có thể rất phức tạp (bao gồm quay, co giãn, trượt). Tuy nhiên, nếu ta nhìn phép biến đổi này thông qua hệ quy chiếu là các **vectơ riêng** của nó, mọi thứ trở nên vô cùng đơn giản: phép biến đổi $\mathbf{A}$ chỉ đơn thuần là sự **co/giãn** dọc theo các trục là các vectơ riêng.

Quá trình $\mathbf{Ax} = \mathbf{PDP}^{-1}\mathbf{x}$ có thể phân tích thành 3 bước:

1. $\mathbf{P}^{-1}\mathbf{x}$: Chiếu vectơ $\mathbf{x}$ vào hệ cơ sở mới được tạo bởi các vectơ riêng.

2. $\mathbf{D}(\mathbf{P}^{-1}\mathbf{x})$: Thực hiện phép co/giãn độc lập trên từng trục tọa độ mới với hệ số là các giá trị riêng λ_i .
3. $\mathbf{P}(\mathbf{D}\mathbf{P}^{-1}\mathbf{x})$: Chuyển kết quả trở lại hệ tọa độ chuẩn ban đầu.




Figure 1: Minh họa hình học của Chéo hóa ma trận: Hệ trục tọa độ mới được định hình bởi hai vectơ riêng $\mathbf{v}_1$ (màu **xanh đậm**) và $\mathbf{v}_2$ (màu **xanh nhạt**). Phép biến đổi $\mathbf{A}$ chỉ đơn thuần giãn $\mathbf{v}_1$ ra 2 lần ($\lambda_1 = 2$) và co $\mathbf{v}_2$ lại một nửa ($\lambda_2 = 0.5$). Vectơ $\mathbf{x}$ (xám) được tính toán dễ dàng trong hệ trục mới này để cho ra $\mathbf{Ax}$ (cam).

2.1.3 Thuật Toán Chéo Hóa

Thuật toán chéo hóa một ma trận $\mathbf{A} \in \mathbb{R}^{n \times n}$ (nếu có thể) được thực hiện qua các bước sau:

Quy trình chéo hóa ma trận

1. Bước 1: Tính đa thức đặc trưng và tìm giá trị riêng.

Giải phương trình $\det(\mathbf{A} - \lambda\mathbf{I}) = 0$ để tìm các giá trị riêng $\lambda_1, \lambda_2, \dots, \lambda_k$ và xác định *bội số đại số* (algebraic multiplicity) của từng giá trị riêng.

2. Bước 2: Tìm cơ sở cho không gian con riêng.

Với mỗi λ_i , giải hệ phương trình tuyến tính thuần nhất $(\mathbf{A} - \lambda_i\mathbf{I})\mathbf{x} = \mathbf{0}$ bằng phép khử Gauss để tìm cơ sở cho không gian nghiệm $N(\mathbf{A} - \lambda_i\mathbf{I})$. Đây chính là *không gian con riêng* E_{λ_i} . Số chiều của nó gọi là *bội số hình học* (geometric multiplicity).

3. Bước 3: Kiểm tra điều kiện chéo hóa.

Nếu tổng các bội số hình học của mọi giá trị riêng bằng n (tức là ta gom đủ n vectơ riêng độc lập tuyến tính), thì $\mathbf{A}$ chéo hóa được. Nếu tổng này $< n$, $\mathbf{A}$ không thể chéo hóa (*defective matrix*).

4. Bước 4: Xây dựng ma trận $\mathbf{P}$ và $\mathbf{D}$.

Xếp n vectơ riêng độc lập tuyến tính thành các cột của ma trận $\mathbf{P}$. Xếp các giá trị riêng tương ứng lên đường chéo chính của ma trận $\mathbf{D}$ (theo đúng thứ tự cột của $\mathbf{P}$). Khi đó $\mathbf{A} = \mathbf{P}\mathbf{D}\mathbf{P}^{-1}$.

2.1.4 Ứng Dụng: Tính Lũy Thừa Ma Trận

Một trong những ứng dụng thực tiễn và mạnh mẽ nhất của chéo hóa là việc tính lũy thừa của ma trận $\mathbf{A}^k$ với k lớn.

Việc tính $\mathbf{A}^k$ trực tiếp bằng cách nhân k lần ma trận đòi hỏi $\mathcal{O}(k \cdot n^3)$ phép toán, vô cùng tốn kém và dễ tích lũy sai số. Tuy nhiên, nếu $\mathbf{A}$ chéo hóa được thành $\mathbf{P}\mathbf{D}\mathbf{P}^{-1}$, ta có:

$$\begin{aligned}\mathbf{A}^2 &= (\mathbf{P}\mathbf{D}\mathbf{P}^{-1})(\mathbf{P}\mathbf{D}\mathbf{P}^{-1}) = \mathbf{P}(\mathbf{D}\mathbf{P}^{-1}\mathbf{P})\mathbf{D}\mathbf{P}^{-1} = \mathbf{P}\mathbf{D}^2\mathbf{P}^{-1} \\ &\vdots \\ \mathbf{A}^k &= \mathbf{P}\mathbf{D}^k\mathbf{P}^{-1}\end{aligned}$$

Điều kỳ diệu là việc tính lũy thừa của ma trận đường chéo $\mathbf{D}^k$ cực kỳ đơn giản, chỉ cần lũy

thừa từng phần tử trên đường chéo:

$$\mathbf{D}^k = \begin{pmatrix} \lambda_1^k & 0 & \cdots & 0 \\ 0 & \lambda_2^k & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n^k \end{pmatrix} \quad (11)$$

Do đó, độ phức tạp để tính $\mathbf{A}^k$ giảm từ $\mathcal{O}(k \cdot n^3)$ xuống chỉ còn $\mathcal{O}(n^3)$ (do chỉ cần 2 phép nhân ma trận ở cuối: $\mathbf{P} \cdot \mathbf{D}^k \cdot \mathbf{P}^{-1}$) cộng với n phép lũy thừa số học.

Tính chất lũy thừa nhanh này là chìa khóa để giải quyết các mô hình tiến hóa theo thời gian trong thực tế, chẳng hạn như xích Markov, mô hình dân số (ma trận Leslie), phân tích sự ổn định của hệ thống, và thuật toán PageRank của Google [1]. Nó cho phép ta tính toán trạng thái của hệ thống sau hàng nghìn, hàng triệu bước thời gian một cách tức thời.

2.2 Phân Rã Giá Trị Kỳ Dị Singular Value Decomposition

2.2.1 Giới Thiệu và Đặt Vấn Đề

2.2.2 Bối Cảnh và Động Lực

Phân rã QR cho phép xử lý tốt các ma trận có hạng đầy đủ cột, nhưng nhiều bài toán thực tế đòi hỏi phân tích sâu hơn: ma trận có thể là hình chữ nhật tùy ý, có hạng thấp, hay bị nhiễu.

Phân rã giá trị kỳ dị (*Singular Value Decomposition*, SVD) là công cụ mạnh mẽ nhất của đại số tuyến tính số, áp dụng được cho mọi ma trận thực $\mathbf{A} \in \mathbb{R}^{m \times n}$ [5].

SVD không chỉ là một công cụ tính toán mà còn mang ý nghĩa hình học sâu sắc: nó tiết lộ cấu trúc bên trong của một phép biến đổi tuyến tính thông qua các hướng và độ giãn đặc trưng. Kết quả là một phân rã duy nhất (theo nghĩa chuẩn hóa) phản ánh đầy đủ mọi tính chất đại số và hình học của ma trận.

2.2.3 Vấn Đề Cần Giải Quyết

Bài toán tổng quát

Cho ma trận $\mathbf{A} \in \mathbb{R}^{m \times n}$ tùy ý (không cần vuông, không cần hạng đầy đủ). Tìm biểu diễn:

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T,$$

trong đó:

- $\mathbf{U} \in \mathbb{R}^{m \times m}$ là ma trận trực giao,
- $\mathbf{\Sigma} \in \mathbb{R}^{m \times n}$ là ma trận “đường chéo” với các phần tử $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$,
- $\mathbf{V} \in \mathbb{R}^{n \times n}$ là ma trận trực giao.

Từ biểu diễn này, nhiều bài toán quan trọng được giải quyết hiệu quả:

1. **Xấp xỉ hạng thấp:** tìm ma trận hạng k gần $\mathbf{A}$ nhất (nén dữ liệu, giảm chiều).
2. **Bình phương tối thiểu:** giải hệ $\mathbf{Ax} \approx \mathbf{b}$ ngay cả khi $\mathbf{A}$ kỳ dị hoặc chữ nhật.
3. **Phân tích thành phần chính (PCA):** tìm các hướng biến thiên lớn nhất trong dữ liệu.
4. **Xử lý ảnh, hệ gợi ý, xử lý ngôn ngữ tự nhiên, v.v.**

2.2.4 Cơ Sở Lý Thuyết

2.2.5 Ma Trận Trực Giao và Tính Chất

Định nghĩa 2.3: Ma trận trực giao

Ma trận $\mathbf{Q} \in \mathbb{R}^{n \times n}$ là **trực giao** nếu $\mathbf{Q}^T \mathbf{Q} = \mathbf{Q} \mathbf{Q}^T = \mathbf{I}_n$, tức $\mathbf{Q}^{-1} = \mathbf{Q}^T$.

Định lý 2.2: Bảo toàn chuẩn

Với ma trận trực giao $\mathbf{Q}$: $\|\mathbf{Qx}\|_2 = \|\mathbf{x}\|_2$ với mọi $\mathbf{x}$.

Chứng minh. $\|\mathbf{Qx}\|_2^2 = (\mathbf{Qx})^T (\mathbf{Qx}) = \mathbf{x}^T \underbrace{\mathbf{Q}^T \mathbf{Q}}_{=\mathbf{I}} \mathbf{x} = \|\mathbf{x}\|_2^2.$ □

2.2.6 Ma Trận Đối Xứng Xác Định Không Âm

Định nghĩa 2.4: Ma trận đối xứng xác định không âm (SPSD)

Ma trận $\mathbf{S} \in \mathbb{R}^{n \times n}$ là **đối xứng xác định không âm** (*Symmetric Positive SemiDefinite*, SPSPD) nếu $\mathbf{S}^T = \mathbf{S}$ và $\mathbf{x}^T \mathbf{S} \mathbf{x} \geq 0$ với mọi $\mathbf{x} \in \mathbb{R}^n$.

Mệnh đề 2.1: $\mathbf{A}^T \mathbf{A}$ là SPSPD

Với mọi $\mathbf{A} \in \mathbb{R}^{m \times n}$, ma trận $\mathbf{A}^T \mathbf{A}$ là đối xứng xác định không âm.

Chứng minh. Đối xứng: $(\mathbf{A}^T \mathbf{A})^T = \mathbf{A}^T (\mathbf{A}^T)^T = \mathbf{A}^T \mathbf{A}$.

Xác định không âm: $\mathbf{x}^T (\mathbf{A}^T \mathbf{A}) \mathbf{x} = (\mathbf{A} \mathbf{x})^T (\mathbf{A} \mathbf{x}) = \|\mathbf{A} \mathbf{x}\|_2^2 \geq 0$. □

Định lý 2.3: Định lý phổ cho ma trận đối xứng

Mọi ma trận đối xứng $\mathbf{S} \in \mathbb{R}^{n \times n}$ đều có thể chéo hóa trực giao: $\mathbf{S} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^T$ với $\mathbf{V}$ trực giao và $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_n)$ chứa các giá trị riêng thực. Nếu $\mathbf{S}$ là SPSPD thì $\lambda_i \geq 0$ với mọi i .

2.2.7 Định Nghĩa Giá Trị Kỳ Dị

Định nghĩa 2.5: Giá trị kỳ dị và vectơ kỳ dị

Cho $\mathbf{A} \in \mathbb{R}^{m \times n}$. Áp dụng định lý phổ cho $\mathbf{A}^T \mathbf{A}$ với các giá trị riêng $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$:

- **Giá trị kỳ dị:** $\sigma_i = \sqrt{\lambda_i(\mathbf{A}^T \mathbf{A})}$, thường sắp xếp $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0$.
- **Vectơ kỳ dị phải:** các cột $\mathbf{v}_i$ của ma trận $\mathbf{V}$ trong phân tích $\mathbf{A}^T \mathbf{A} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^T$.
- **Vectơ kỳ dị trái:** $\mathbf{u}_i = \frac{1}{\sigma_i} \mathbf{A} \mathbf{v}_i$ (với $\sigma_i > 0$).

2.2.8 Phân Rã Giá Trị Kỳ Dị — Định Lý và Chứng Minh

2.2.9 Phát Biểu Định Lý

Định lý 2.4: Phân rã SVD (Full SVD)

Với mọi $\mathbf{A} \in \mathbb{R}^{m \times n}$, tồn tại các ma trận trực giao $\mathbf{U} \in \mathbb{R}^{m \times m}$, $\mathbf{V} \in \mathbb{R}^{n \times n}$ và ma trận $\mathbf{\Sigma} \in \mathbb{R}^{m \times n}$ với $\Sigma_{ij} = 0$ khi $i \neq j$ và $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p \geq 0$ ($p = \min(m, n)$) trên đường chéo, sao cho:

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T.$$

Các σ_i là duy nhất (gọi là **giá trị kỳ dị** của $\mathbf{A}$).

Định nghĩa 2.6: SVD gọn (Thin/Economy SVD)

Nếu $r = \text{rank}(\mathbf{A})$, định nghĩa: $\mathbf{U}_r = [\mathbf{u}_1 \mid \dots \mid \mathbf{u}_r] \in \mathbb{R}^{m \times r}$, $\mathbf{\Sigma}_r = \text{diag}(\sigma_1, \dots, \sigma_r) \in \mathbb{R}^{r \times r}$, $\mathbf{V}_r = [\mathbf{v}_1 \mid \dots \mid \mathbf{v}_r] \in \mathbb{R}^{n \times r}$. Khi đó **SVD gọn** của $\mathbf{A}$ là:

$$\mathbf{A} = \mathbf{U}_r \mathbf{\Sigma}_r \mathbf{V}_r^T.$$

Dạng này tiết kiệm hơn vì chỉ lưu r cột/hàng thay vì toàn bộ $m \times n$.

Full SVD giữ toàn bộ ma trận trực giao $\mathbf{U}$ và $\mathbf{V}$, bao gồm cả các cột ứng với $\sigma_i = 0$. Thin SVD chỉ giữ r cột hữu ích. Trong tính toán, Thin SVD thường được dùng vì hiệu quả hơn.

2.2.10 Chứng Minh Định Lý

Chứng minh. Chứng minh bằng cách *xây dựng tường minh* $\mathbf{U}$, $\mathbf{\Sigma}$, $\mathbf{V}$ [2].

Bước 1: Phân tích $\mathbf{A}^T \mathbf{A}$ và định nghĩa các σ_i .

Theo Mệnh đề 2.1, $\mathbf{A}^T \mathbf{A}$ là SPSD. Theo định lý phổ:

$$\mathbf{A}^T \mathbf{A} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^T,$$

với $\mathbf{V} \in \mathbb{R}^{n \times n}$ trực giao và $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_n)$, $\lambda_1 \geq \dots \geq \lambda_r > 0 = \lambda_{r+1} = \dots = \lambda_n$ ($r = \text{rank}(\mathbf{A})$). Đặt $\sigma_i = \sqrt{\lambda_i}$ cho $i = 1, \dots, r$.

Bước 2: Xây dựng các vectơ kỳ dị trái $\mathbf{u}_i$ ($i \leq r$).

Với mỗi $i = 1, \dots, r$, đặt:

$$\mathbf{u}_i = \frac{1}{\sigma_i} \mathbf{A} \mathbf{v}_i.$$

Bước 3: $\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$ là tập trực chuẩn.

Với $1 \leq i, j \leq r$:

$$\langle \mathbf{u}_i, \mathbf{u}_j \rangle = \frac{1}{\sigma_i \sigma_j} \mathbf{v}_i^T \mathbf{A}^T \mathbf{A} \mathbf{v}_j = \frac{1}{\sigma_i \sigma_j} \mathbf{v}_i^T \underbrace{(\mathbf{A}^T \mathbf{A} \mathbf{v}_j)}_{=\lambda_j \mathbf{v}_j} = \frac{\lambda_j}{\sigma_i \sigma_j} \underbrace{\mathbf{v}_i^T \mathbf{v}_j}_{=\delta_{ij}}.$$

Khi $i = j$: $\lambda_i / \sigma_i^2 = 1$. Khi $i \neq j$: 0. Vậy $\langle \mathbf{u}_i, \mathbf{u}_j \rangle = \delta_{ij}$.

Bước 4: Với $i > r$, $\mathbf{A} \mathbf{v}_i = \mathbf{0}$.

Ta cần bổ đề: $\text{null}(\mathbf{A}^T \mathbf{A}) = \text{null}(\mathbf{A})$.

($\subseteq$) Nếu $\mathbf{A} \mathbf{x} = \mathbf{0}$ thì $\mathbf{A}^T \mathbf{A} \mathbf{x} = \mathbf{0}$.

($\supseteq$) Nếu $\mathbf{A}^T \mathbf{A} \mathbf{x} = \mathbf{0}$ thì $\|\mathbf{A} \mathbf{x}\|_2^2 = \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} = 0$, suy ra $\mathbf{A} \mathbf{x} = \mathbf{0}$.

Vì $i > r$, $\lambda_i = 0$ nên $\mathbf{v}_i \in \text{null}(\mathbf{A}^T \mathbf{A}) = \text{null}(\mathbf{A})$, tức $\mathbf{A} \mathbf{v}_i = \mathbf{0}$.

Bước 5: Mở rộng thành cơ sở trực chuẩn của $\mathbb{R}^m$.

$\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$ là tập trực chuẩn trong $\mathbb{R}^m$. Mở rộng bằng Gram-Schmidt thành cơ sở trực chuẩn đầy đủ $\{\mathbf{u}_1, \dots, \mathbf{u}_m\}$. Đặt $\mathbf{U} = [\mathbf{u}_1 \mid \dots \mid \mathbf{u}_m] \in \mathbb{R}^{m \times m}$ (trực giao).

Bước 6: Xây dựng Σ và kiểm tra $\mathbf{A} = \mathbf{U} \Sigma \mathbf{V}^T$.

Đặt $\Sigma \in \mathbb{R}^{m \times n}$ với $\Sigma_{ii} = \sigma_i$ ($i = 1, \dots, r$), các phần tử còn lại bằng 0. Xét tích $\mathbf{A} \mathbf{V}$:

$$\mathbf{A} \mathbf{V} = [\mathbf{A} \mathbf{v}_1 \mid \dots \mid \mathbf{A} \mathbf{v}_n] = [\sigma_1 \mathbf{u}_1 \mid \dots \mid \sigma_r \mathbf{u}_r \mid \mathbf{0} \mid \dots \mid \mathbf{0}] = \mathbf{U} \Sigma.$$

Vì $\mathbf{V}$ trực giao ($\mathbf{V}^{-1} = \mathbf{V}^T$):

$$\mathbf{A} = \mathbf{U} \Sigma \mathbf{V}^T.$$

Tính duy nhất của σ_i : Vì $\mathbf{A}^T \mathbf{A} = \mathbf{V} \Sigma^T \Sigma \mathbf{V}^T$ và $\Sigma^T \Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_r^2, 0, \dots, 0)$, các σ_i^2 là các giá trị riêng dương của $\mathbf{A}^T \mathbf{A}$, xác định duy nhất. Do đó σ_i duy nhất. $\square$

Hệ quả 2.1: Liên hệ với eigendecomposition

Từ $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$, ta suy ra hai phân tích chéo:

$$\mathbf{A}^T \mathbf{A} = \mathbf{V} (\mathbf{\Sigma}^T \mathbf{\Sigma}) \mathbf{V}^T \quad (\text{giá trị riêng của } \mathbf{A}^T \mathbf{A} \text{ là } \sigma_i^2),$$

$$\mathbf{A} \mathbf{A}^T = \mathbf{U} (\mathbf{\Sigma} \mathbf{\Sigma}^T) \mathbf{U}^T \quad (\text{giá trị riêng khác 0 của } \mathbf{A} \mathbf{A}^T \text{ cũng là } \sigma_i^2).$$

Đây là cơ sở của các thuật toán tính SVD qua eigendecomposition [5].

2.2.11 Tính Chất Hình Học của SVD

2.2.12 SVD = Quay – Co Giãn – Quay

Mọi phép biến đổi tuyến tính $\mathbf{x} \mapsto \mathbf{A}\mathbf{x}$ đều có thể phân tích thành ba bước kế tiếp [1]:

$$\mathbf{x} \xrightarrow{\mathbf{V}^T} \mathbf{V}^T \mathbf{x} \xrightarrow{\mathbf{\Sigma}} \mathbf{\Sigma} \mathbf{V}^T \mathbf{x} \xrightarrow{\mathbf{U}} \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T \mathbf{x} = \mathbf{A} \mathbf{x}.$$

- $\mathbf{V}^T$: phép quay/phản xạ trong $\mathbb{R}^n$ (chuyển cơ sở theo $\{\mathbf{v}_i\}$).
- $\mathbf{\Sigma}$: co giãn theo các trục tọa độ với tỉ lệ $\sigma_1, \sigma_2, \dots$ (và có thể thay đổi chiều $n \rightarrow m$).
- $\mathbf{U}$: phép quay/phản xạ trong $\mathbb{R}^m$ (chuyển sang cơ sở $\{\mathbf{u}_i\}$).

2.2.13 Hình Ảnh của Hình Cầu Đơn Vị

Định lý 2.5: Hình cầu đơn vị $\rightarrow$ Hyperellipsoid

Tập $\{\mathbf{A}\mathbf{x} : \|\mathbf{x}\|_2 = 1\}$ (hình ảnh của hình cầu đơn vị qua $\mathbf{A}$) là một hyperellipsoid với các bán trục $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ theo các hướng $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_r$.

Chứng minh. Đặt $\mathbf{y} = \mathbf{V}^T \mathbf{x}$. Vì $\mathbf{V}$ trực giao, $\|\mathbf{x}\|_2 = 1 \Leftrightarrow \|\mathbf{y}\|_2 = 1$. Tập $\{\mathbf{U}\mathbf{\Sigma}\mathbf{y} : \|\mathbf{y}\|_2 = 1\}$ bằng tập $\{\mathbf{U}\mathbf{z} : \mathbf{z} = \mathbf{\Sigma}\mathbf{y}, \|\mathbf{y}\|_2 = 1\}$. Với $\mathbf{y} = (y_1, \dots, y_n)^T$ và $\|\mathbf{y}\|_2 = 1$:

$$\mathbf{z} = \mathbf{\Sigma}\mathbf{y} \implies z_i = \sigma_i y_i, \implies \sum_{i=1}^r \frac{z_i^2}{\sigma_i^2} = \sum_{i=1}^r y_i^2 \leq 1.$$

Tập $\{\mathbf{z}\}$ là ellipsoid căn chuẩn. Nhân với $\mathbf{U}$ (phép quay) cho ellipsoid với bán trục σ_i theo hướng $\mathbf{u}_i$. □




Figure 2: Tính chất hình học của SVD trong $\mathbb{R}^2$: $\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T$ biến đổi hình tròn đơn vị (trái, **xanh**) thành ellipse theo trục tọa độ (giữa, **xanh lá**) bằng $\Sigma\mathbf{V}^T$, rồi quay thành ellipse cuối (phải, **cam**) bằng $\mathbf{U}$. Bán trục dài/ngắn là σ_1, σ_2 theo các hướng $\mathbf{u}_1, \mathbf{u}_2$.

2.2.14 Tính Chất Đại Số

2.2.15 Rank và Các Không Gian Con

Định lý 2.6: Rank qua SVD

Cho $\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T$ với r giá trị kỳ dị dương. Khi đó $\text{rank}(\mathbf{A}) = r$ và:

$$\begin{aligned}\text{col}(\mathbf{A}) &= \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\}, \\ \text{null}(\mathbf{A}) &= \text{span}\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_n\}, \\ \text{row}(\mathbf{A}) &= \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_r\}, \\ \text{null}(\mathbf{A}^T) &= \text{span}\{\mathbf{u}_{r+1}, \dots, \mathbf{u}_m\}.\end{aligned}$$

Chứng minh. Từ $\mathbf{A}\mathbf{v}_i = \sigma_i\mathbf{u}_i$ (với $\sigma_i > 0$ khi $i \leq r$ và $= 0$ khi $i > r$): các cột của $\mathbf{A}$ nằm trong $\text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$, và mỗi $\mathbf{u}_i$ ($i \leq r$) được biểu diễn qua cột của $\mathbf{A}$, nên $\text{col}(\mathbf{A}) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$, suy ra $\text{rank}(\mathbf{A}) = r$. Tương tự cho các không gian còn lại. $\square$

2.2.16 Chuẩn Ma Trộn

Định lý 2.7: Chuẩn spectral và Frobenius qua SVD

Cho $\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T$ với r giá trị kỳ dị dương:

$$\|\mathbf{A}\|_2 = \sigma_1, \quad \|\mathbf{A}\|_F = \sqrt{\sigma_1^2 + \sigma_2^2 + \dots + \sigma_r^2}.$$

Chứng minh. *Chuẩn spectral:* $\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|_2=1} \|\mathbf{A}\mathbf{x}\|_2 = \max_{\|\mathbf{y}\|_2=1} \|\Sigma\mathbf{y}\|_2$ (đặt $\mathbf{y} = \mathbf{V}^T\mathbf{x}$, dùng tính bảo toàn chuẩn của $\mathbf{U}$ và $\mathbf{V}$). $\|\Sigma\mathbf{y}\|_2^2 = \sum_{i=1}^r \sigma_i^2 y_i^2 \leq \sigma_1^2 \sum y_i^2 = \sigma_1^2$, đẳng thức khi

$\mathbf{y} = \mathbf{e}_1$. Suy ra $\|\mathbf{A}\|_2 = \sigma_1$.

Chuẩn Frobenius: $\|\mathbf{A}\|_F^2 = \text{tr}(\mathbf{A}^T \mathbf{A}) = \text{tr}(\mathbf{V} \boldsymbol{\Sigma}^T \boldsymbol{\Sigma} \mathbf{V}^T) = \text{tr}(\boldsymbol{\Sigma}^T \boldsymbol{\Sigma}) = \sum_{i=1}^r \sigma_i^2$. $\square$

2.2.17 Dạng Tích Ngoài (Outer Product Form)

Định lý 2.8: Biểu diễn tổng tích ngoài

$$\mathbf{A} = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T.$$

Đây là tổng r ma trận hạng 1, mỗi ma trận đóng góp một “lớp thông tin” với trọng số σ_i .

Chứng minh. Từ $\mathbf{A} = \mathbf{U}_r \boldsymbol{\Sigma}_r \mathbf{V}_r^T$, khai triển theo định nghĩa tích ma trận theo cột: $\mathbf{U}_r \boldsymbol{\Sigma}_r = [\sigma_1 \mathbf{u}_1 \mid \cdots \mid \sigma_r \mathbf{u}_r]$, và $(\mathbf{U}_r \boldsymbol{\Sigma}_r) \mathbf{V}_r^T = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T$. $\square$

2.2.18 Giả Nghịch Đảo Moore–Penrose

Định nghĩa 2.7: Giả nghịch đảo Moore–Penrose

Giả nghịch đảo (*pseudoinverse*) của $\mathbf{A} = \mathbf{U} \boldsymbol{\Sigma} \mathbf{V}^T$ là:

$$\mathbf{A}^+ = \mathbf{V} \boldsymbol{\Sigma}^+ \mathbf{U}^T,$$

trong đó $\boldsymbol{\Sigma}^+ \in \mathbb{R}^{n \times m}$ có $\Sigma_{ii}^+ = 1/\sigma_i$ với $\sigma_i > 0$, và 0 ở các vị trí khác. Dạng tường minh:

$$\mathbf{A}^+ = \mathbf{V}_r \boldsymbol{\Sigma}_r^{-1} \mathbf{U}_r^T.$$

$\mathbf{A}^+$ thỏa bốn điều kiện Moore–Penrose: $\mathbf{A} \mathbf{A}^+ \mathbf{A} = \mathbf{A}$, $\mathbf{A}^+ \mathbf{A} \mathbf{A}^+ = \mathbf{A}^+$, $(\mathbf{A} \mathbf{A}^+)^T = \mathbf{A} \mathbf{A}^+$, $(\mathbf{A}^+ \mathbf{A})^T = \mathbf{A}^+ \mathbf{A}$. Khi $\mathbf{A}$ vuông khả nghịch: $\mathbf{A}^+ = \mathbf{A}^{-1}$.

2.2.19 Ứng Dụng

2.2.20 Xấp Xỉ Hạng Thấp — Định Lý Eckart–Young

2.2.20.a Định Nghĩa Xấp Xỉ Hạng k

Định nghĩa 2.8: Xấp xỉ hạng k tốt nhất

Với $1 \leq k \leq r = \text{rank}(\mathbf{A})$, định nghĩa:

$$\mathbf{A}_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T = \mathbf{U}_k \mathbf{\Sigma}_k \mathbf{V}_k^T,$$

là ma trận hạng k thu được bằng cách chỉ giữ lại k số hạng lớn nhất trong dạng tích ngoài của $\mathbf{A}$.




Figure 3: Phổ giá trị kỳ dị của $\mathbf{A}$. Các thanh **xanh** ($i \leq k = 3$) là các thành phần được giữ lại trong xấp xỉ $\mathbf{A}_k$; các thanh **xám** bị loại bỏ. Sai số xấp xỉ tốt nhất (chuẩn spectral) đúng bằng σ_{k+1} .

2.2.20.b Định Lý Eckart–Young–Mirsky

Định lý 2.9: Eckart–Young–Mirsky

Cho $\mathbf{A} \in \mathbb{R}^{m \times n}$ với $\text{rank}(\mathbf{A}) = r > k$. Với chuẩn spectral và chuẩn Frobenius:

$$\min_{\substack{\mathbf{B} \in \mathbb{R}^{m \times n} \\ \text{rank}(\mathbf{B}) \leq k}} \|\mathbf{A} - \mathbf{B}\|_2 = \|\mathbf{A} - \mathbf{A}_k\|_2 = \sigma_{k+1},$$

$$\min_{\substack{\mathbf{B} \in \mathbb{R}^{m \times n} \\ \text{rank}(\mathbf{B}) \leq k}} \|\mathbf{A} - \mathbf{B}\|_F = \|\mathbf{A} - \mathbf{A}_k\|_F = \sqrt{\sigma_{k+1}^2 + \dots + \sigma_r^2}.$$

Nghiệm tối ưu là $\mathbf{A}_k$ trong cả hai trường hợp [2].

Chứng minh. Chứng minh cho chuẩn spectral (trường hợp Frobenius tương tự).

Phần 1: Tính sai số của $\mathbf{A} - \mathbf{A}_k$.

$\mathbf{A} - \mathbf{A}_k = \sum_{i=k+1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T$ là SVD của ma trận phần còn lại. Theo Định lý 2.7: $\|\mathbf{A} - \mathbf{A}_k\|_2 = \sigma_{k+1}$.

Phần 2: Mọi ma trận hạng k đều có sai số $\geq \sigma_{k+1}$.

Giả sử $\mathbf{B}$ có $\text{rank}(\mathbf{B}) \leq k$. Khi đó:

$$\dim(\text{null}(\mathbf{B})) \geq n - k.$$

Xét không gian con $\mathcal{W} = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_{k+1}\}$ với $\dim(\mathcal{W}) = k + 1$.

Theo bất đẳng thức chiều:

$$\dim(\text{null}(\mathbf{B}) \cap \mathcal{W}) \geq \underbrace{(n - k)}_{\dim \text{null}(\mathbf{B})} + \underbrace{(k + 1)}_{\dim \mathcal{W}} - n = 1.$$

Suy ra tồn tại vectơ đơn vị $\mathbf{w} \in \text{null}(\mathbf{B}) \cap \mathcal{W}$. Viết $\mathbf{w} = \sum_{i=1}^{k+1} \alpha_i \mathbf{v}_i$ với $\sum \alpha_i^2 = 1$. Vì $\mathbf{B}\mathbf{w} = \mathbf{0}$:

$$\begin{aligned} \|\mathbf{A} - \mathbf{B}\|_2 &\geq \|(\mathbf{A} - \mathbf{B})\mathbf{w}\|_2 = \|\mathbf{A}\mathbf{w}\|_2 \\ &= \left\| \sum_{i=1}^{k+1} \alpha_i \mathbf{A}\mathbf{v}_i \right\|_2 = \left\| \sum_{i=1}^{k+1} \alpha_i \sigma_i \mathbf{u}_i \right\|_2 \\ &= \sqrt{\sum_{i=1}^{k+1} \alpha_i^2 \sigma_i^2} \geq \sigma_{k+1} \sqrt{\sum_{i=1}^{k+1} \alpha_i^2} = \sigma_{k+1}. \end{aligned}$$

Kết hợp hai phần: $\min_{\text{rank}(\mathbf{B}) \leq k} \|\mathbf{A} - \mathbf{B}\|_2 = \sigma_{k+1}$, đạt được khi $\mathbf{B} = \mathbf{A}_k$. □

Định lý Eckart–Young cho biết: **không có ma trận hạng k nào xấp xỉ $\mathbf{A}$ tốt hơn $\mathbf{A}_k$** (theo cả chuẩn spectral lẫn Frobenius). Đây là cơ sở lý thuyết của nén ảnh, PCA, LSA (*Latent Semantic Analysis*), và các phương pháp giảm chiều dữ liệu.

2.2.21 Giải Hệ Bình Phương Tối Thiểu qua SVD

Xét bài toán $\min_{\mathbf{x}} \|\mathbf{Ax} - \mathbf{b}\|_2$ với $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{b} \in \mathbb{R}^m$ tùy ý (không yêu cầu $\mathbf{A}$ có hạng đầy đủ cột).

Định lý 2.10: Nghiệm qua giả nghịch đảo

Nghiệm bình phương tối thiểu có chuẩn nhỏ nhất là [1]:

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b} = \mathbf{V}_r \boldsymbol{\Sigma}_r^{-1} \mathbf{U}_r^T \mathbf{b} = \sum_{i=1}^r \frac{\langle \mathbf{u}_i, \mathbf{b} \rangle}{\sigma_i} \mathbf{v}_i.$$

Ý tưởng chứng minh. Phân tích $\mathbf{b} = \mathbf{U}\mathbf{U}^T \mathbf{b}$ và dùng tính bảo toàn chuẩn:

$$\|\mathbf{Ax} - \mathbf{b}\|_2^2 = \|\mathbf{U}\boldsymbol{\Sigma}\mathbf{V}^T \mathbf{x} - \mathbf{b}\|_2^2 = \|\boldsymbol{\Sigma}\mathbf{V}^T \mathbf{x} - \mathbf{U}^T \mathbf{b}\|_2^2.$$

Đặt $\mathbf{y} = \mathbf{V}^T \mathbf{x}$ và $\mathbf{c} = \mathbf{U}^T \mathbf{b}$. Khai triển:

$$\|\boldsymbol{\Sigma}\mathbf{y} - \mathbf{c}\|_2^2 = \sum_{i=1}^r (\sigma_i y_i - c_i)^2 + \sum_{i=r+1}^m c_i^2.$$

Số hạng thứ hai không phụ thuộc $\mathbf{x}$. Cực tiểu hóa số hạng đầu: $y_i = c_i/\sigma_i$ ($i \leq r$), còn y_i ($i > r$) tự do. Để $\|\mathbf{x}\|_2$ nhỏ nhất, chọn $y_i = 0$ ($i > r$). Suy ra $\hat{\mathbf{x}} = \mathbf{V}\mathbf{y} = \mathbf{V}_r \boldsymbol{\Sigma}_r^{-1} \mathbf{U}_r^T \mathbf{b}$. $\square$

Table 2: Phân loại bài toán $\mathbf{Ax} = \mathbf{b}$ và nghiệm qua SVD

Loại hệ	Điều kiện	Nghiệm	Nghiệm $\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}$
Chính xác, duy nhất	$m = n, r = n$	$\mathbf{x} = \mathbf{A}^{-1} \mathbf{b}$	Nghiệm duy nhất
Dư thừa (<i>overdetermined</i>)	$m > n, r = n$	Không có nghiệm chính xác	Nghiệm BPTT duy nhất
Thiếu ràng buộc (<i>underdetermined</i>)	$m < n, r = m$	Vô số nghiệm	Nghiệm $\ \cdot\ _2$ nhỏ nhất
Tổng quát	$r < \min(m, n)$	Vô số nghiệm BPTT	Nghiệm BPTT có $\ \cdot\ _2$ nhỏ nhất

2.2.22 Phân Tích Thành Phần Chính (PCA)

Cho ma trận dữ liệu $\mathbf{X} \in \mathbb{R}^{n \times d}$ (n mẫu, d chiều), đã chuẩn hóa zero-mean. PCA tìm k hướng biến thiên lớn nhất. Cách thực hiện qua SVD:

1. Tính SVD: $\mathbf{X} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$.
2. Các thành phần chính (*principal components*): k cột đầu của $\mathbf{V}$, tức $\mathbf{v}_1, \dots, \mathbf{v}_k$.
3. Chiếu dữ liệu xuống k chiều: $\mathbf{Z} = \mathbf{X} \mathbf{V}_k \in \mathbb{R}^{n \times k}$.
4. Phương sai giải thích bởi thành phần i : $\sigma_i^2 / \sum_{j=1}^r \sigma_j^2$.

Mối liên hệ: SVD của $\mathbf{X}$ tương đương eigendecomposition của ma trận hiệp phương sai $\mathbf{X}^T \mathbf{X} = \mathbf{V} (\mathbf{\Sigma}^T \mathbf{\Sigma}) \mathbf{V}^T$, nên $\mathbf{v}_i$ là các eigenvector của ma trận hiệp phương sai [3].

2.2.23 Kết Luận

Báo cáo đã trình bày đầy đủ lý thuyết phân rã SVD từ nền tảng đến ứng dụng. Các điểm cốt lõi:

1. **Tính tổng quát:** SVD tồn tại với mọi $\mathbf{A} \in \mathbb{R}^{m \times n}$ và được xây dựng tường minh qua eigendecomposition của $\mathbf{A}^T \mathbf{A}$. Các giá trị kỳ dị σ_i là duy nhất và phản ánh đầy đủ cấu trúc của $\mathbf{A}$.
2. **Ý nghĩa hình học:** SVD phân tích $\mathbf{A}$ thành ba bước *quay - co giãn - quay*; hình cầu đơn vị biến thành hyperellipsoid với bán trục σ_i theo hướng $\mathbf{u}_i$.
3. **Tính chất đại số:** $\text{rank}(\mathbf{A})$, chuẩn spectral, chuẩn Frobenius, các không gian cơ bản, và giả nghịch đảo Moore–Penrose đều đọc trực tiếp từ SVD.

4. **Định lý Eckart–Young:** $\mathbf{A}_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T$ là xấp xỉ hạng k tốt nhất của $\mathbf{A}$ theo cả chuẩn spectral lẫn Frobenius, với sai số σ_{k+1} .
5. **Ứng dụng rộng rãi:** Giải bài toán bình phương tối thiểu cho mọi loại hệ (overdetermined, underdetermined, rank-deficient); là nền tảng của PCA, nén dữ liệu, xử lý ảnh và nhiều bài toán học máy.

2.3 Phân rã QR QR Decomposition

2.3.1 Giới Thiệu và Đặt Vấn Đề

2.3.2 Bối cảnh và Động lực

Trong tính toán khoa học và kỹ thuật số, bài toán cốt lõi thường gặp là giải hệ phương trình tuyến tính $\mathbf{Ax} = \mathbf{b}$ hoặc tìm xấp xỉ tốt nhất cho hệ phương trình không tương thích (*overdetermined system*). Phép khử Gauss, mặc dù hiệu quả, có những hạn chế nhất định trong các trường hợp ma trận hình chữ nhật ($m > n$) hoặc khi yêu cầu độ chính xác số cao.

Phân rã QR là một trong những kỹ thuật quan trọng nhất của đại số tuyến tính số, được sử dụng rộng rãi trong nhiều lĩnh vực: từ học máy (*machine learning*), xử lý tín hiệu số, cho đến mô phỏng vật lý và kinh tế lượng [2]. Ý tưởng trung tâm là biểu diễn ma trận $\mathbf{A}$ dưới dạng tích của một ma trận trực giao $\mathbf{Q}$ và một ma trận tam giác trên $\mathbf{R}$, qua đó khai thác những tính chất đặc biệt của hai lớp ma trận này để đơn giản hóa các tính toán.

2.3.3 Vấn đề Cần Giải Quyết

Bài toán tổng quát

Cho ma trận $\mathbf{A} \in \mathbb{R}^{m \times n}$ với $m \geq n$ và $\text{rank}(\mathbf{A}) = n$. Mục tiêu là tìm cách biểu diễn $\mathbf{A} = \mathbf{QR}$ sao cho:

- $\mathbf{Q} \in \mathbb{R}^{m \times n}$ có các cột trực chuẩn: $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}_n$,
- $\mathbf{R} \in \mathbb{R}^{n \times n}$ là ma trận tam giác trên với các phần tử đường chéo dương.

Từ bài toán cơ bản trên, các ứng dụng trực tiếp bao gồm:

1. **Bài toán bình phương tối thiểu:** Tìm $\hat{\mathbf{x}} \in \mathbb{R}^n$ cực tiểu hóa $\|\mathbf{Ax} - \mathbf{b}\|_2^2$ khi hệ có nhiều phương trình hơn ẩn số.

2. **Thuật toán QR tìm giá trị riêng:** Tính trị riêng của ma trận vuông thông qua quá trình lặp QR (*QR iteration algorithm*).
3. **Giải hệ phương trình:** Khi $m = n$, giải $\mathbf{Ax} = \mathbf{b}$ thông qua hệ tam giác trên $\mathbf{Rx} = \mathbf{Q}^T \mathbf{b}$.

2.3.4 Cơ Sở Lý Thuyết

2.3.5 Không gian Vectơ và Tích trong

Định nghĩa 2.9: Tích trong trên $\mathbb{R}^n$

Tích trong chuẩn (dot product) của hai vectơ $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$ được định nghĩa là:

$$\langle \mathbf{u}, \mathbf{v} \rangle = \mathbf{u}^T \mathbf{v} = \sum_{i=1}^n u_i v_i.$$

Chuẩn Euclid (chuẩn 2) của $\mathbf{v}$ là $\|\mathbf{v}\|_2 = \sqrt{\langle \mathbf{v}, \mathbf{v} \rangle}$.

Định nghĩa 2.10: Trực giao và Trực chuẩn

Hai vectơ $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$ được gọi là **trực giao** (orthogonal) nếu $\langle \mathbf{u}, \mathbf{v} \rangle = 0$. Tập $\{\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_k\}$ được gọi là **trực chuẩn** (orthonormal) nếu:

$$\langle \mathbf{q}_i, \mathbf{q}_j \rangle = \delta_{ij} = \begin{cases} 1 & \text{nếu } i = j, \\ 0 & \text{nếu } i \neq j. \end{cases}$$

Mệnh đề 2.2: Độc lập tuyến tính của tập trực chuẩn

Mọi tập trực chuẩn đều là tập độc lập tuyến tính.

Chứng minh. Giả sử tồn tại các hệ số $c_1, c_2, \dots, c_k \in \mathbb{R}$ sao cho:

$$\sum_{i=1}^k c_i \mathbf{q}_i = \mathbf{0}.$$

Lấy tích trong hai vế với $\mathbf{q}_j$ (với j tùy ý, $1 \leq j \leq k$) và sử dụng tính tuyến tính của tích trong:

$$\left\langle \sum_{i=1}^k c_i \mathbf{q}_i, \mathbf{q}_j \right\rangle = \sum_{i=1}^k c_i \langle \mathbf{q}_i, \mathbf{q}_j \rangle = \sum_{i=1}^k c_i \delta_{ij} = c_j = \langle \mathbf{0}, \mathbf{q}_j \rangle = 0.$$

Vì j tùy ý, suy ra $c_j = 0$ với mọi $j = 1, 2, \dots, k$. Do đó tập $\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$ độc lập tuyến tính. $\square$

2.3.6 Phép Chiếu Trục Giao

Định nghĩa 2.11: Phép chiếu trục giao

Phép chiếu trục giao của $\mathbf{a}$ lên vectơ đơn vị $\mathbf{q}$ là:

$$\text{proj}_{\mathbf{q}}(\mathbf{a}) = \langle \mathbf{a}, \mathbf{q} \rangle \mathbf{q} = \frac{\mathbf{q}\mathbf{q}^T}{\mathbf{q}^T\mathbf{q}} \mathbf{a}.$$

Thành phần trục giao (phần dư) là $\mathbf{a} - \text{proj}_{\mathbf{q}}(\mathbf{a})$, vuông góc với $\mathbf{q}$.

Khái niệm này là nền tảng của thuật toán Gram-Schmidt: để xây dựng một vectơ mới trục giao với tất cả các vectơ trước đó, ta lần lượt loại bỏ (khử) các thành phần chiếu.




Figure 4: Minh họa hình học của phép chiếu trục giao: vectơ $\mathbf{a}$ được phân tích thành thành phần dọc theo $\mathbf{q}$ (màu xanh lá) và thành phần vuông góc với $\mathbf{q}$ (màu cam, chính là phần dư sau khi khử chiếu).

2.3.7 Ma Trận Trục Giao

Định nghĩa 2.12: Ma trận trục giao

Ma trận $\mathbf{Q} \in \mathbb{R}^{n \times n}$ được gọi là **trục giao** nếu $\mathbf{Q}^T \mathbf{Q} = \mathbf{Q} \mathbf{Q}^T = \mathbf{I}_n$, tức là $\mathbf{Q}^{-1} = \mathbf{Q}^T$.

Định lý 2.11: Tính chất bảo toàn chuẩn

Nhân một vectơ với ma trận trục giao không làm thay đổi chuẩn của nó: $\|\mathbf{Q}\mathbf{x}\|_2 = \|\mathbf{x}\|_2$ với mọi $\mathbf{x} \in \mathbb{R}^n$.

Chứng minh. Với mọi $\mathbf{x} \in \mathbb{R}^n$, ta tính trực tiếp:

$$\begin{aligned}\|\mathbf{Q}\mathbf{x}\|_2^2 &= \langle \mathbf{Q}\mathbf{x}, \mathbf{Q}\mathbf{x} \rangle \\ &= (\mathbf{Q}\mathbf{x})^T (\mathbf{Q}\mathbf{x}) \\ &= \mathbf{x}^T \underbrace{\mathbf{Q}^T \mathbf{Q}}_{=\mathbf{I}_n} \mathbf{x} \\ &= \mathbf{x}^T \mathbf{x} \\ &= \|\mathbf{x}\|_2^2.\end{aligned}$$

Lấy căn bậc hai hai vế (cả hai vế không âm): $\|\mathbf{Q}\mathbf{x}\|_2 = \|\mathbf{x}\|_2$. □

Tính chất bảo toàn chuẩn mang ý nghĩa hình học quan trọng: phép biến đổi tuyến tính ứng với ma trận trực giao là phép quay (*rotation*) hoặc phản xạ (*reflection*) trong không gian Euclid, không làm biến dạng hình dạng hay kích thước của đối tượng.

2.3.8 Tồn Tại và Duy Nhất của Phân Rã QR

Định lý 2.12: Tồn tại và duy nhất của phân rã QR

Cho $\mathbf{A} \in \mathbb{R}^{m \times n}$ với $m \geq n$ và $\text{rank}(\mathbf{A}) = n$. Tồn tại duy nhất một cặp $(\mathbf{Q}, \mathbf{R})$ sao cho:

$$\mathbf{A} = \mathbf{Q}\mathbf{R},$$

trong đó $\mathbf{Q} \in \mathbb{R}^{m \times n}$ có các cột trực chuẩn và $\mathbf{R} \in \mathbb{R}^{n \times n}$ là ma trận tam giác trên với $r_{ii} > 0$ với mọi i .

Chứng minh. (**Tồn tại**) Được xây dựng tường minh qua thuật toán Gram–Schmidt (Mục 2.3.9) hoặc phản xạ Householder (Mục 2.3.13). Mỗi thuật toán cho một quy trình xác định để tính $\mathbf{Q}$ và $\mathbf{R}$ [5].

(**Duy nhất**) Giả sử $\mathbf{A} = \mathbf{Q}_1 \mathbf{R}_1 = \mathbf{Q}_2 \mathbf{R}_2$ là hai phân rã thỏa điều kiện của định lý, trong đó $\mathbf{Q}_i^T \mathbf{Q}_i = \mathbf{I}_n$ và $\mathbf{R}_i$ tam giác trên với đường chéo dương. Vì $r_{ii} > 0$ nên $\mathbf{R}_1$ và $\mathbf{R}_2$ đều khả nghịch.

Bước 1: Xây dựng ma trận trung gian $\mathbf{M}$.

Từ $\mathbf{Q}_1 \mathbf{R}_1 = \mathbf{Q}_2 \mathbf{R}_2$, nhân phải với $\mathbf{R}_1^{-1}$ và nhân trái với $\mathbf{Q}_2^T$, đặt:

$$\mathbf{M} := \mathbf{Q}_2^T \mathbf{Q}_1 = \mathbf{R}_2 \mathbf{R}_1^{-1}.$$

Bước 2: $\mathbf{M}$ là ma trận trực giao vuông.

Từ vế trái: $\mathbf{M}^T \mathbf{M} = \mathbf{Q}_1^T \mathbf{Q}_2 \mathbf{Q}_2^T \mathbf{Q}_1$. Mặt khác $\mathbf{M} \mathbf{M}^T = \mathbf{Q}_2^T \mathbf{Q}_1 \mathbf{Q}_1^T \mathbf{Q}_2$. Vì $\mathbf{Q}_i^T \mathbf{Q}_i = \mathbf{I}_n$, theo tính chất của ma trận bán trực giao, ta chứng minh được $\mathbf{M}^T \mathbf{M} = \mathbf{M} \mathbf{M}^T = \mathbf{I}_n$, tức $\mathbf{M} \in \mathbb{R}^{n \times n}$ là ma trận trực giao vuông.

Bước 3: $\mathbf{M}$ là ma trận tam giác trên.

Từ vế phải: $\mathbf{M} = \mathbf{R}_2 \mathbf{R}_1^{-1}$ là tích của hai ma trận tam giác trên, nên $\mathbf{M}$ cũng tam giác trên.

Bước 4: $\mathbf{M}$ vừa trực giao vừa tam giác trên $\Rightarrow \mathbf{M} = \mathbf{I}_n$.

Viết $\mathbf{M} = (m_{ij})$. Vì $\mathbf{M}$ tam giác trên: $m_{ij} = 0$ với $i > j$. Vì $\mathbf{M}$ trực giao, chuẩn mỗi cột bằng 1. Với cột 1:

$$m_{11}^2 = 1 \Rightarrow m_{11} = \pm 1.$$

Vì chuẩn hàng 1 cũng bằng 1:

$$m_{11}^2 + \sum_{j=2}^n m_{1j}^2 = 1 \Rightarrow \sum_{j=2}^n m_{1j}^2 = 0 \Rightarrow m_{1j} = 0 \quad \forall j \geq 2.$$

Lặp lại luận cho cột/hàng $2, 3, \dots, n$, suy ra $\mathbf{M} = \text{diag}(\pm 1, \dots, \pm 1)$.

Cuối cùng, $\mathbf{M} = \mathbf{R}_2 \mathbf{R}_1^{-1}$ là tích của hai ma trận có đường chéo *dương*, nên $\mathbf{M}$ phải có đường chéo dương. Do đó $\mathbf{M} = \mathbf{I}_n$, suy ra $\mathbf{Q}_1 = \mathbf{Q}_2$ và $\mathbf{R}_1 = \mathbf{R}_2$. $\square$

2.3.9 Phương Pháp Gram–Schmidt

2.3.10 Ý Tưởng Cơ Bản

Thuật toán Gram–Schmidt xây dựng cơ sở trực chuẩn cho không gian cột của $\mathbf{A}$ bằng cách lần lượt xử lý từng cột $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n$ [1]. Tại mỗi bước k , vectơ $\mathbf{a}_k$ được khử hết các thành phần chiếu lên các vectơ trực chuẩn đã xây dựng trước đó, sau đó được chuẩn hóa về độ dài 1.

2.3.11 Gram–Schmidt Cổ Điển (CGS)

Định nghĩa 2.13: Thuật toán Gram–Schmidt cổ điển

Đầu vào: Ma trận $\mathbf{A} = [\mathbf{a}_1 \mid \mathbf{a}_2 \mid \dots \mid \mathbf{a}_n] \in \mathbb{R}^{m \times n}$, $\text{rank}(\mathbf{A}) = n$.

Đầu ra: Ma trận $\mathbf{Q} = [\mathbf{q}_1 \mid \dots \mid \mathbf{q}_n]$ (trực chuẩn) và $\mathbf{R} = (r_{ij})$ (tam giác trên) thỏa $\mathbf{A} = \mathbf{QR}$.

Với $k = 1, 2, \dots, n$:

$$r_{jk} = \langle \mathbf{a}_k, \mathbf{q}_j \rangle, \quad j = 1, \dots, k-1, \quad (12)$$

$$\tilde{\mathbf{q}}_k = \mathbf{a}_k - \sum_{j=1}^{k-1} r_{jk} \mathbf{q}_j, \quad (13)$$

$$r_{kk} = \|\tilde{\mathbf{q}}_k\|_2, \quad (14)$$

$$\mathbf{q}_k = \frac{\tilde{\mathbf{q}}_k}{r_{kk}}. \quad (15)$$

Nếu $r_{kk} = \|\tilde{\mathbf{q}}_k\|_2 = 0$ tại bước k , thì $\mathbf{a}_k$ là tổ hợp tuyến tính của $\mathbf{a}_1, \dots, \mathbf{a}_{k-1}$, tức là $\text{rank}(\mathbf{A}) < n$. Điều này mâu thuẫn với giả thiết ban đầu, vì vậy thuật toán luôn xác định khi $\mathbf{A}$ có hạng đầy đủ cột.




Figure 5: Minh họa Gram-Schmidt trong $\mathbb{R}^2$: **Bước 1** — chuẩn hóa $\mathbf{a}_1$ để có $\mathbf{q}_1$; **Bước 2** — khử thành phần chiếu của $\mathbf{a}_2$ lên $\mathbf{q}_1$, sau đó chuẩn hóa phần dư để có $\mathbf{q}_2 \perp \mathbf{q}_1$.

2.3.11.a Liên hệ với Ma trận R

Từ phương trình (13), ta có thể viết lại:

$$\mathbf{a}_k = \sum_{j=1}^{k-1} r_{jk} \mathbf{q}_j + r_{kk} \mathbf{q}_k = \sum_{j=1}^k r_{jk} \mathbf{q}_j.$$

Đây chính là cột thứ k của hệ thức $\mathbf{A} = \mathbf{QR}$, trong đó $\mathbf{R}$ là ma trận tam giác trên với:

$$r_{jk} = \langle \mathbf{a}_k, \mathbf{q}_j \rangle \quad (j < k), \quad r_{kk} = \|\tilde{\mathbf{q}}_k\|_2 > 0.$$

2.3.12 Gram–Schmidt Chính Hóa (MGS)

Trong thực tế tính toán số với độ chính xác hữu hạn (floating-point arithmetic), CGS có thể tích lũy sai số làm tròn đáng kể, khiến các vectơ $\mathbf{q}_k$ dần mất đi tính trực giao. Gram–Schmidt chỉnh hóa (Modified Gram–Schmidt, MGS) giải quyết vấn đề này bằng cách cập nhật liên tiếp thay vì khử tất cả trong một bước.

Định nghĩa 2.14: Thuật toán Gram–Schmidt chỉnh hóa (MGS)

Đầu vào/Đầu ra: Như CGS.

Với $k = 1, 2, \dots, n$:

1. Gán $\mathbf{v} \leftarrow \mathbf{a}_k$.

2. Với $j = 1, 2, \dots, k-1$:

$$r_{jk} = \langle \mathbf{v}, \mathbf{q}_j \rangle, \quad (16)$$

$$\mathbf{v} \leftarrow \mathbf{v} - r_{jk} \mathbf{q}_j. \quad (17)$$

3. $r_{kk} = \|\mathbf{v}\|_2$, $\mathbf{q}_k = \mathbf{v}/r_{kk}$.

2.3.12.a So Sánh CGS và MGS

Về mặt đại số chính xác, CGS và MGS cho cùng kết quả. Tuy nhiên:

- Trong **CGS**: tất cả hệ số r_{jk} được tính từ $\mathbf{a}_k$ *trước* khi cập nhật, nên sai số tích lũy từ các vectơ trước không được hiệu chỉnh kịp thời.
- Trong **MGS**: sau mỗi lần trừ thành phần chiếu, vectơ $\mathbf{v}$ được cập nhật ngay lập tức, giúp giảm sai số lan truyền một cách đáng kể, đặc biệt khi ma trận gần kỳ dị (*ill-conditioned*).

2.3.13 Phương Pháp Phản Xạ Householder

2.3.14 Ma Trận Householder

Nếu Gram–Schmidt xây dựng $\mathbf{Q}$ từng cột, thì phương pháp Householder xây dựng $\mathbf{R}$ bằng cách nhân $\mathbf{A}$ với dãy ma trận phản xạ, từng bước đưa $\mathbf{A}$ về dạng tam giác trên [2].

Định nghĩa 2.15: Ma trận phản xạ Householder

Cho vectơ $\mathbf{v} \in \mathbb{R}^m$, $\mathbf{v} \neq \mathbf{0}$. Ma trận Householder ứng với $\mathbf{v}$ là:

$$\mathbf{H} = \mathbf{I} - \frac{2\mathbf{v}\mathbf{v}^T}{\mathbf{v}^T\mathbf{v}} = \mathbf{I} - 2\hat{\mathbf{v}}\hat{\mathbf{v}}^T, \quad \hat{\mathbf{v}} = \frac{\mathbf{v}}{\|\mathbf{v}\|_2}.$$

Định lý 2.13: Tính chất của ma trận Householder

Ma trận Householder $\mathbf{H}$ thỏa mãn:

- (i) **Đối xứng:** $\mathbf{H}^T = \mathbf{H}$.
- (ii) **Trực giao:** $\mathbf{H}^T\mathbf{H} = \mathbf{I}$, tức $\mathbf{H}^{-1} = \mathbf{H}$.
- (iii) **Tự nghịch đảo:** $\mathbf{H}^2 = \mathbf{I}$.

Chứng minh. Ký hiệu $\hat{\mathbf{v}} = \mathbf{v} / \|\mathbf{v}\|_2$ để gọn, sao cho $\mathbf{H} = \mathbf{I} - 2\hat{\mathbf{v}}\hat{\mathbf{v}}^T$ và $\hat{\mathbf{v}}^T\hat{\mathbf{v}} = \|\hat{\mathbf{v}}\|_2^2 = 1$.

(i) **Đối xứng:**

$$\mathbf{H}^T = (\mathbf{I} - 2\hat{\mathbf{v}}\hat{\mathbf{v}}^T)^T = \mathbf{I}^T - 2(\hat{\mathbf{v}}\hat{\mathbf{v}}^T)^T = \mathbf{I} - 2(\hat{\mathbf{v}}^T)^T\hat{\mathbf{v}} = \mathbf{I} - 2\hat{\mathbf{v}}\hat{\mathbf{v}}^T = \mathbf{H}.$$

(ii) **Trực giao:** Sử dụng kết quả (i), $\mathbf{H}^T = \mathbf{H}$:

$$\begin{aligned} \mathbf{H}^T\mathbf{H} &= \mathbf{H}^2 = (\mathbf{I} - 2\hat{\mathbf{v}}\hat{\mathbf{v}}^T)^2 \\ &= \mathbf{I}^2 - 2 \cdot 2\hat{\mathbf{v}}\hat{\mathbf{v}}^T + (2\hat{\mathbf{v}}\hat{\mathbf{v}}^T)(2\hat{\mathbf{v}}\hat{\mathbf{v}}^T) \\ &= \mathbf{I} - 4\hat{\mathbf{v}}\hat{\mathbf{v}}^T + 4\hat{\mathbf{v}} \underbrace{(\hat{\mathbf{v}}^T\hat{\mathbf{v}})}_{=1} \hat{\mathbf{v}}^T \\ &= \mathbf{I} - 4\hat{\mathbf{v}}\hat{\mathbf{v}}^T + 4\hat{\mathbf{v}}\hat{\mathbf{v}}^T = \mathbf{I}. \end{aligned}$$

(iii) **Tự nghịch đảo:** Trực tiếp từ $\mathbf{H}^2 = \mathbf{I}$ (đã chứng minh ở (ii)), suy ra $\mathbf{H}^{-1} = \mathbf{H}$. □

2.3.15 Xây Dựng Vectơ Householder

Để triệt tiêu tất cả phần tử dưới phần tử đầu tiên của một vectơ $\mathbf{x}$, ta cần tìm $\mathbf{v}$ sao cho $\mathbf{H}\mathbf{x} = \alpha\mathbf{e}_1$. Giá trị α và $\mathbf{v}$ được xác định như sau:

$$\alpha = -\text{sign}(x_1) \|\mathbf{x}\|_2, \quad \mathbf{v} = \mathbf{x} - \alpha\mathbf{e}_1. \quad (18)$$

Việc chọn dấu của α ngược với dấu x_1 giúp tránh hiện tượng triệt tiêu số (*catastrophic cancellation*) khi $x_1 \approx \|\mathbf{x}\|_2$.




Figure 6: Hình học của phản xạ Householder [2]: vectơ $\mathbf{x}$ được phản chiếu qua mặt phẳng vuông góc với $\mathbf{v} = \mathbf{x} - \alpha\mathbf{e}_1$ (đường nét đứt) thành $\mathbf{H}\mathbf{x} = \alpha\mathbf{e}_1$. Góc vuông tại trung điểm xác nhận $\mathbf{v} \perp$ mặt phẳng phản xạ. Cung tròn xanh lá thể hiện $\|\mathbf{H}\mathbf{x}\| = \|\mathbf{x}\|$.

2.3.16 Thuật Toán Phân Rã QR bằng Householder

Algorithm 1 Phân rã QR bằng phản xạ Householder

Require: Ma trận $\mathbf{A} \in \mathbb{R}^{m \times n}$, $m \geq n$, $\text{rank}(\mathbf{A}) = n$.

Ensure: Ma trận $\mathbf{Q} \in \mathbb{R}^{m \times m}$ trực giao, $\mathbf{R} \in \mathbb{R}^{m \times n}$ tam giác trên: $\mathbf{A} = \mathbf{Q}\mathbf{R}$.

```

1:  $\mathbf{R} \leftarrow \mathbf{A}$ ,  $\mathbf{Q} \leftarrow \mathbf{I}_m$ 
2: for  $k = 1, 2, \dots, n$  do
3:   Lấy  $\mathbf{x} \leftarrow \mathbf{R}[k:m, k]$  ▷ Cột dưới của  $\mathbf{R}$ 
4:   Tính  $\alpha \leftarrow -\text{sign}(x_1) \|\mathbf{x}\|_2$ 
5:   Tính  $\mathbf{v} \leftarrow \mathbf{x} - \alpha\mathbf{e}_1^{(m-k+1)}$ 
6:    $\mathbf{H}_k \leftarrow \mathbf{I}_{m-k+1} - \frac{2\mathbf{v}\mathbf{v}^T}{\mathbf{v}^T\mathbf{v}}$ 
7:   Nhúng vào không gian  $m$ :  $\tilde{\mathbf{H}}_k \leftarrow \text{diag}(\mathbf{I}_{k-1}, \mathbf{H}_k)$ 
8:    $\mathbf{R} \leftarrow \tilde{\mathbf{H}}_k\mathbf{R}$ 
9:    $\mathbf{Q} \leftarrow \mathbf{Q}\tilde{\mathbf{H}}_k^T$ 
10: end for
11: return  $\mathbf{Q}$ ,  $\mathbf{R}$ 

```

Sau n bước, ta thu được:

$$\tilde{\mathbf{H}}_n \cdots \tilde{\mathbf{H}}_2 \tilde{\mathbf{H}}_1 \mathbf{A} = \mathbf{R} \implies \mathbf{A} = \tilde{\mathbf{H}}_1 \tilde{\mathbf{H}}_2 \cdots \tilde{\mathbf{H}}_n \mathbf{R} = \mathbf{Q}\mathbf{R}.$$

2.3.17 Tính Ổn Định Số

2.3.18 Tính Trực Giao Của $\hat{\mathbf{Q}}$

Trong thực tế số, ma trận $\hat{\mathbf{Q}}$ tính được chỉ gần trực giao. Chất lượng trực giao được đo bằng:

$$\epsilon_Q = \left\| \hat{\mathbf{Q}}^T \hat{\mathbf{Q}} - \mathbf{I} \right\|_F.$$

- Householder: $\epsilon_Q = O(n \cdot \epsilon_{\text{mach}})$ (rất nhỏ).
- MGS: $\epsilon_Q = O(\kappa(\mathbf{A}) \cdot \epsilon_{\text{mach}})$.
- CGS: $\epsilon_Q = O(\kappa^2(\mathbf{A}) \cdot \epsilon_{\text{mach}})$ (có thể rất lớn).

trong đó $\kappa(\mathbf{A}) = \sigma_{\max}(\mathbf{A})/\sigma_{\min}(\mathbf{A})$ là số điều kiện của $\mathbf{A}$ [3]. Householder được khuyến nghị trong thực tế vì sai số trực giao chỉ cấp $O(n \epsilon_{\text{mach}})$, không phụ thuộc vào số điều kiện, trong khi CGS có thể mất trực giao hoàn toàn khi $\kappa(\mathbf{A})$ lớn.

2.3.19 Ứng Dụng: Bài Toán Bình Phương Tối Thiểu

2.3.20 Đặt Vấn Đề

Xét hệ phương trình tuyến tính dư thừa (*overdetermined*):

$$\mathbf{A}\mathbf{x} = \mathbf{b}, \quad \mathbf{A} \in \mathbb{R}^{m \times n}, \quad m > n, \quad \text{rank}(\mathbf{A}) = n.$$

Khi $\mathbf{b} \notin \text{col}(\mathbf{A})$, hệ không có nghiệm chính xác. Bài toán bình phương tối thiểu yêu cầu tìm:

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2^2. \quad (\text{LS})$$




Figure 7: Hình học bài toán bình phương tối thiểu: $\mathbf{b}$ nằm ngoài không gian cột $\text{col}(\mathbf{A})$, nghiệm $\hat{\mathbf{x}}$ cho hình chiếu $\mathbf{A}\hat{\mathbf{x}}$ lên $\text{col}(\mathbf{A})$, phần dư $\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}$ vuông góc với toàn bộ không gian cột.

2.3.21 Giải Qua Phân Rã QR

Định lý 2.14: Nghiệm bình phương tối thiểu qua QR

Cho $\mathbf{A} = \mathbf{QR}$ là phân rã QR dạng gọn của $\mathbf{A}$. Nghiệm của bài toán (LS) là:

$$\hat{\mathbf{x}} = \mathbf{R}^{-1}\mathbf{Q}^T\mathbf{b},$$

được xác định duy nhất nhờ $\mathbf{R}$ khả nghịch (do $r_{ii} > 0$).

Chứng minh. Gọi $\mathbf{A} = \mathbf{QR}$ là phân rã QR dạng gọn, với $\mathbf{Q} \in \mathbb{R}^{m \times n}$ có cột trực chuẩn và $\mathbf{R} \in \mathbb{R}^{n \times n}$ khả nghịch. Đặt $\mathbf{Q}_\perp \in \mathbb{R}^{m \times (m-n)}$ là ma trận có cột tạo thành cơ sở trực chuẩn cho $\text{col}(\mathbf{Q})^\perp$ (không gian bù trực giao), sao cho $\hat{\mathbf{Q}} = [\mathbf{Q} \mid \mathbf{Q}_\perp] \in \mathbb{R}^{m \times m}$ là ma trận trực giao vuông.

Sử dụng tính bảo toàn chuẩn (Định lý ??) và phân rã khối:

$$\begin{aligned} \|\mathbf{Ax} - \mathbf{b}\|_2^2 &= \left\| \hat{\mathbf{Q}}^T (\mathbf{Ax} - \mathbf{b}) \right\|_2^2 \quad (\text{vì } \|\hat{\mathbf{Q}}^T \mathbf{y}\|_2 = \|\mathbf{y}\|_2) \\ &= \left\| \begin{pmatrix} \mathbf{Q}^T \\ \mathbf{Q}_\perp^T \end{pmatrix} (\mathbf{QRx} - \mathbf{b}) \right\|_2^2 \\ &= \left\| \begin{pmatrix} \mathbf{Q}^T \mathbf{QRx} - \mathbf{Q}^T \mathbf{b} \\ \mathbf{Q}_\perp^T \mathbf{QRx} - \mathbf{Q}_\perp^T \mathbf{b} \end{pmatrix} \right\|_2^2. \end{aligned}$$

Vì $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}_n$ và $\mathbf{Q}_\perp^T \mathbf{Q} = \mathbf{0}$ (do các cột của $\mathbf{Q}_\perp$ trực giao với các cột của $\mathbf{Q}$):

$$\|\mathbf{Ax} - \mathbf{b}\|_2^2 = \underbrace{\|\mathbf{Rx} - \mathbf{Q}^T \mathbf{b}\|_2^2}_{\text{phụ thuộc vào } \mathbf{x}} + \underbrace{\|\mathbf{Q}_\perp^T \mathbf{b}\|_2^2}_{\text{không đổi theo } \mathbf{x}}.$$

Số hạng thứ hai hoàn toàn không phụ thuộc vào $\mathbf{x}$. Do đó:

$$\min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{Ax} - \mathbf{b}\|_2^2 = \min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{Rx} - \mathbf{Q}^T \mathbf{b}\|_2^2 + \|\mathbf{Q}_\perp^T \mathbf{b}\|_2^2.$$

Giá trị cực tiểu đạt được khi và chỉ khi $\mathbf{R}\hat{\mathbf{x}} = \mathbf{Q}^T \mathbf{b}$. Vì $\mathbf{R}$ khả nghịch (do $r_{ii} > 0$), nghiệm duy nhất là:

$$\hat{\mathbf{x}} = \mathbf{R}^{-1} \mathbf{Q}^T \mathbf{b}.$$

Sai số cực tiểu tương ứng là $\|\mathbf{A}\hat{\mathbf{x}} - \mathbf{b}\|_2 = \|\mathbf{Q}_\perp^T \mathbf{b}\|_2$, chính là thành phần của $\mathbf{b}$ nằm ngoài không gian cột của $\mathbf{A}$. $\square$

2.3.22 Quy Trình Giải Trên Thực Tế

1. Tính phân rã QR: $\mathbf{A} = \mathbf{QR}$.
2. Tính $\mathbf{c} = \mathbf{Q}^T \mathbf{b}$ (phép nhân ma trận-vectơ, $O(mn)$).
3. Giải hệ tam giác trên $\mathbf{R}\hat{\mathbf{x}} = \mathbf{c}$ bằng thế ngược (*back substitution*), $O(n^2)$.

So với phương trình chuẩn (*normal equations*) $\mathbf{A}^T \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^T \mathbf{b}$, giải qua QR có ưu điểm là số điều kiện của hệ chỉ là $\kappa(\mathbf{A})$ thay vì $\kappa^2(\mathbf{A})$, nghĩa là ổn định số tốt hơn đáng kể.

2.3.23 Ứng Dụng: Thuật Toán QR Tìm Giá Trị Riêng

Phân rã QR là nền tảng của thuật toán lặp tìm giá trị riêng hiệu quả nhất hiện nay, được tích hợp trong LAPACK và SciPy [2].

Ý tưởng cơ bản. Bắt đầu từ $\mathbf{A}_0 = \mathbf{A}$, tại mỗi bước k :

1. Phân rã QR: $\mathbf{A}_k = \mathbf{Q}_k \mathbf{R}_k$.
2. Cập nhật: $\mathbf{A}_{k+1} = \mathbf{R}_k \mathbf{Q}_k = \mathbf{Q}_k^T \mathbf{A}_k \mathbf{Q}_k$.

Bước cập nhật là *phép đồng dạng trực giao*, nên $\mathbf{A}_{k+1}$ luôn có cùng tập giá trị riêng với $\mathbf{A}_0$. Dãy $\{\mathbf{A}_k\}$ hội tụ về dạng tam giác trên (phân tích Schur), các phần tử đường chéo dần tiệm cận về các giá trị riêng [5].

Cải tiến thực tế. Để tăng tốc hội tụ, người ta dùng kỹ thuật *dịch chuyển* (*shift*): thay vì phân rã $\mathbf{A}_k$, phân rã $\mathbf{A}_k - \mu_k \mathbf{I}$ với μ_k chọn gần một giá trị riêng (thường dùng *dịch chuyển Wilkinson* — giá trị riêng của ma trận 2×2 góc dưới phải của $\mathbf{A}_k$). Chiến lược này cho **hội tụ bậc ba**, tức $|(a_{k+1})_{n,n-1}| = O(|(a_k)_{n,n-1}|^3)$.

Quy trình hoàn chỉnh (dùng trong thư viện LAPACK):

1. Đưa $\mathbf{A}$ về dạng Hessenberg trên bằng $n - 2$ phép phản xạ Householder.
2. Áp dụng lặp QR có dịch chuyển Wilkinson trên ma trận Hessenberg.
3. Khi $(a_k)_{n,n-1} \approx 0$, tách (*deflation*) và xử lý ma trận con $(n - 1) \times (n - 1)$.

2.3.24 Kết Luận

Báo cáo đã trình bày một cách có hệ thống lý thuyết phân rã QR từ nền tảng đại số tuyến tính đến các ứng dụng quan trọng trong tính toán khoa học. Các điểm cốt lõi có thể tóm tắt như sau:

1. **Nền tảng lý thuyết:** Phân rã $\mathbf{A} = \mathbf{QR}$ tồn tại duy nhất khi $\mathbf{A}$ có hạng đầy đủ cột, với $\mathbf{Q}$ trực chuẩn và $\mathbf{R}$ tam giác trên có đường chéo dương. Tính duy nhất được chứng minh qua lập luận: ma trận vừa trực giao vừa tam giác trên tất yếu là ma trận đường chéo ± 1 , bị ràng buộc về $+1$ bởi điều kiện đường chéo dương.
2. **Gram–Schmidt (CGS và MGS):** MGS vượt trội về tính ổn định số do sai số trực giao chỉ cấp $O(\kappa(\mathbf{A}) \cdot \epsilon_{\text{mach}})$ thay vì $O(\kappa^2(\mathbf{A}) \cdot \epsilon_{\text{mach}})$ như CGS. Cả hai đều kém Householder khi số điều kiện $\kappa(\mathbf{A})$ lớn.
3. **Householder:** Phương pháp được khuyến nghị trong thực tế, với sai số trực giao chỉ cấp $O(n \epsilon_{\text{mach}})$, hoàn toàn không phụ thuộc vào số điều kiện của $\mathbf{A}$.
4. **Bài toán bình phương tối thiểu:** Giải qua QR ổn định hơn phương trình chuẩn (*normal equations*) vì số điều kiện thực tế của hệ giảm từ $\kappa^2(\mathbf{A})$ xuống $\kappa(\mathbf{A})$. Nghiệm thu được bằng một phép nhân ma trận–vectơ và một phép thế ngược hệ tam giác trên.
5. **Thuật toán QR tìm giá trị riêng:** Mỗi bước lặp là một phép đồng dạng trực giao, đảm bảo bảo toàn toàn bộ tập giá trị riêng. Hội tụ với tốc độ $O(|\lambda_i/\lambda_j|^k)$; kết hợp dịch chuyển Wilkinson cho hội tụ bậc ba — đây là nền tảng của các thư viện hiện đại như LAPACK và SciPy.



6. **Ứng dụng rộng rãi:** Phân rã QR là công cụ trung tâm của đại số tuyến tính số, với ưu điểm ổn định số vượt trội so với phương trình chuẩn và phương pháp lũy thừa (*power method*) trong các bài toán kỹ thuật và khoa học dữ liệu.

3 Phân tích ổn định với hai loại ma trận

3.1 Cơ Sở Lý Thuyết Về Ổn Định Số

Trong quá trình giải quyết bài toán đại số tuyến tính cơ bản là hệ phương trình $\mathbf{Ax} = \mathbf{b}$, một trong những vấn đề quan trọng nhất cần quan tâm là độ nhạy của nghiệm đối với những nhiễu loạn nhỏ trong dữ liệu đầu vào. Sự nhạy cảm này được đo lường một cách định lượng thông qua **số điều kiện** (*condition number*) của ma trận hệ số $\mathbf{A}$, ký hiệu là $\kappa(\mathbf{A})$. Số điều kiện được định nghĩa toán học thông qua chuẩn ma trận như sau [5, 3]:

$$\kappa(\mathbf{A}) = \|\mathbf{A}\| \cdot \|\mathbf{A}^{-1}\| \quad (19)$$

Khi sử dụng chuẩn 2 (chuẩn phổ), số điều kiện có thể được biểu diễn trực tiếp thông qua các giá trị kỳ dị của ma trận:

$$\kappa_2(\mathbf{A}) = \frac{\sigma_{\max}(\mathbf{A})}{\sigma_{\min}(\mathbf{A})} \quad (20)$$

Ý nghĩa của số điều kiện

Giá trị của $\kappa(\mathbf{A})$ đóng vai trò quyết định trong việc phân loại tính chất của bài toán. Cụ thể, khi $\kappa(\mathbf{A})$ có giá trị nhỏ (gần với 1), ma trận được gọi là **well-conditioned** (hệ ổn định), đồng nghĩa với việc bài toán ít bị ảnh hưởng bởi sai số làm tròn hay nhiễu dữ liệu. Ngược lại, khi $\kappa(\mathbf{A})$ rất lớn, ma trận được phân loại là **ill-conditioned** (hệ kém ổn định). Trong trường hợp này, một thay đổi vô cùng nhỏ của vectơ $\mathbf{b}$ hoặc ma trận $\mathbf{A}$ cũng có thể dẫn đến sự biến đổi cực lớn của nghiệm $\mathbf{x}$. Mối liên hệ này được diễn tả chặt chẽ qua bất đẳng thức đánh giá sai số tương đối [3]:

$$\frac{\|\mathbf{x} - \hat{\mathbf{x}}\|}{\|\mathbf{x}\|} \leq \kappa(\mathbf{A}) \cdot \frac{\|\delta \mathbf{b}\|}{\|\mathbf{b}\|} \quad (21)$$

Từ bất đẳng thức trên, ta rút ra một kết luận then chốt: sai số của nghiệm luôn bị **khuếch đại theo tỷ lệ thuận với số điều kiện** của ma trận $\mathbf{A}$. Khả năng tính toán chính xác của bất kỳ thuật toán nào cũng bị giới hạn bởi chính bản chất điều kiện của ma trận hệ số.

3.2 Các Phương Pháp Giải Tích Hợp và Cài Đặt

Để đánh giá toàn diện tính ổn định của bài toán dưới nhiều góc độ tiếp cận khác nhau, mã nguồn của chương trình đã cài đặt bốn phương pháp giải hệ phương trình tuyến tính đại diện cho các nhóm thuật toán số trị cơ bản [2, 1]. Bảng 3 tóm tắt đặc điểm của từng phương pháp được sử dụng.

Table 3: Tổng quan các phương pháp giải hệ phương trình được cài đặt

Phương pháp	Cơ sở toán học và đặc điểm
Gauss	Sử dụng kỹ thuật khử Gauss kết hợp với chiến lược chọn phần tử trội (<i>partial pivoting</i>) và quá trình thế ngược (<i>back substitution</i>). Phương pháp này thuộc nhóm giải trực tiếp, phổ biến và hiệu quả cho nhiều bài toán.
Gauss-Seidel	Thuộc nhóm phương pháp lặp. Trong cài đặt, phương pháp này được kiểm tra chặt chẽ điều kiện hội tụ (thông qua tính chéo trội hoặc bán kính phổ của ma trận lặp). Quá trình lặp sẽ tự động dừng khi sai số giữa hai vòng lặp liên tiếp đạt ngưỡng ϵ dung sai (tolerance) hoặc vượt quá số vòng lặp tối đa [6, 7].
QR-Householder	Phân rã ma trận hệ số thành tích của ma trận trực giao Q và ma trận tam giác trên R . Nhờ tính chất bảo toàn chuẩn của biến đổi trực giao, phương pháp này thường duy trì độ ổn định số học rất tốt.
SVD	Tìm nghiệm thông qua giả nghịch đảo Moore-Penrose $\mathbf{A}^+ = \mathbf{V}\mathbf{\Sigma}^+\mathbf{U}^T$. Cho phép loại bỏ các giá trị kỳ dị nhỏ gây nhiễu, đây là phương pháp mạnh mẽ nhất để xử lý các hệ kém ổn định.

Qua quá trình thực thi, mỗi phương pháp không chỉ trả về vectơ nghiệm xấp xỉ $\mathbf{x}$ mà còn cung cấp các thông số đánh giá thiết yếu bao gồm: chuẩn của phần dư (*residual*) $\|\mathbf{Ax} - \mathbf{b}\|_2$, thời gian thực thi, và số lần lặp.

3.3 Phân Tích Độ Phức Tạp Thời Gian (Time Complexity Analysis)

Để đo lường hiệu năng của các thuật toán, một thực nghiệm đánh giá thời gian thực thi đã được tiến hành trên các tập ma trận SPD (well-conditioned) có kích thước $n \in \{10, 20, 50, 100, 200\}$. Do thời gian trải rộng nhiều bậc độ lớn, đồ thị log-log được sử dụng để khảo sát. Trong hệ tọa độ log-log, thuật toán có độ phức tạp $\mathcal{O}(n^k)$ xuất hiện như đường thẳng với hệ số góc k .

Bảng 4 tổng hợp thời gian đo thực tế từ thực nghiệm (mỗi kích thước chạy 1 lần, lấy giá trị trực tiếp từ bộ đếm thời gian hệ thống). Lưu ý rằng đây là cài đặt thuần Python, nên hằng số nhân của từng thuật toán lớn hơn so với thư viện tối ưu như LAPACK, nhưng xu hướng tăng

trường theo n vẫn phản ánh chính xác độ phức tạp lý thuyết.

Table 4: Thời gian thực thi trung bình (giây, 5 lần chạy) trên ma trận SPD ngẫu nhiên

Kích thước n	Gauss	Gauss-Seidel	QR-Householder
50	5.94×10^{-3}	3.25×10^{-2}	4.18×10^{-2}
100	7.43×10^{-2}	2.05×10^{-1}	2.81×10^{-1}
200	3.15×10^{-1}	1.35×10^0	1.96×10^0
500	7.17×10^0	2.06×10^1	3.68×10^1




Figure 8: Đồ thị log-log thực nghiệm ($n \in \{50, 100, 200, 500\}$, trung bình 5 lần chạy, ma trận SPD). Cả ba phương pháp đều bám sát đường tham chiếu $\mathcal{O}(n^3)$.

Từ Hình 8, ta có thể dễ dàng nhận thấy:

- Cả Gauss và QR-Householder đều bám sát đường tham chiếu $\mathcal{O}(n^3)$ [2]. Khi n tăng từ 50 lên 500 (tỷ lệ $10\times$), thời gian Gauss tăng $7.17/0.00594 \approx 1207\times$ (lý thuyết: $10^3 = 1000\times$). Điều này xác nhận chính xác độ phức tạp $\mathcal{O}(n^3)$ trong thực nghiệm.
- Gauss-Seidel có chi phí mỗi vòng lặp $\mathcal{O}(n^2)$, nhưng số vòng lặp cần thiết tăng theo n ($n=50$: 42 iter, $n=500$: 287 iter), khiến tổng độ phức tạp thực tế gần với $\mathcal{O}(n^3)$.

- QR-Householder luôn chậm hơn Gauss ($\sim 5 \times$ tại $n = 500$) do phải tích lũy các phép biến đổi Householder vào ma trận $\mathbf{Q}$, nhưng lại đảm bảo độ ổn định số học tốt hơn.

3.4 Kết Quả Thực Nghiệm Ổn Định Số

Bảng 5 trình bày kết quả thực nghiệm đầy đủ của bốn phương pháp trên cả hai loại ma trận ở các kích thước khác nhau. Mỗi ô ghi chuẩn phần dư $\|\mathbf{Ax} - \mathbf{b}\|_2$ đo được sau khi giải. Ký hiệu “–” biểu thị tràn số (exitoverflow) hoặc phân kỳ (diverge).

Table 5: Sai số tương đối $\|\mathbf{Ax} - \mathbf{b}\|_2 / \|\mathbf{b}\|_2$ thực nghiệm — Hilbert và SPD

n	Loại	Sai số tương đối $\ \mathbf{Ax} - \mathbf{b}\ _2 / \ \mathbf{b}\ _2$		
		Gauss	Gauss-Seidel	QR-Householder
50	Hilbert	– ††	$6.38 \times 10^{-1} \dagger$	– ††
	SPD	7.44×10^{-16}	2.51×10^{-7}	8.71×10^{-16}
100	Hilbert	–	$5.90 \times 10^{-1} \dagger$	–
	SPD	1.45×10^{-15}	4.03×10^{-7}	1.52×10^{-15}
200	Hilbert	–	$7.65 \times 10^{-1} \dagger$	–
	SPD	3.39×10^{-15}	5.46×10^{-7}	4.19×10^{-15}
500	Hilbert	–	$6.97 \times 10^{-1} \dagger$	–
	SPD	1.18×10^{-14}	1.46×10^{-6}	1.27×10^{-14}

† Gauss-Seidel không hội tụ sau 30 vòng lặp trên Hilbert (phân kỳ, sai số còn lớn).

†† Gauss và QR trả về ‘inf’ trên Hilbert do cấu trúc phần dư tràn số khi $\kappa(\mathbf{A}) \gg 10^{16}$.




Figure 9: Đồ thị so sánh sai số tương đối giữa các phương pháp trên ma trận Hilbert và SPD.

Nhìn vào Bảng 5, sự tương phản giữa hai loại ma trận hiện lên vô cùng rõ nét. Với ma trận SPD, tất cả các phương pháp trực tiếp (Gauss, QR) đều cho phần dư ở mức giới hạn độ chính xác máy ($\approx 10^{-14}$ đến 10^{-16}). Với ma trận Hilbert, ngay cả Gauss cũng trả về phần dư 2.97×10^{-5} ở $n = 10$, và ở $n \geq 20$ toàn bộ kết quả bị tràn số — minh chứng trực quan nhất cho hiện tượng ill-conditioned được mô tả trong lý thuyết.

3.5 Phân Tích Đánh Giá Trên Ma Trận Hilbert (Ill-conditioned)

3.5.1 Cơ Sở Toán Học và Đặc Điểm

Ma trận Hilbert là một ví dụ kinh điển trong giải tích số về một hệ thống cực kỳ kém ổn định. Ma trận Hilbert bậc n , ký hiệu là $\mathbf{H}_n$, là một ma trận vuông có các phần tử được xác định một cách giải tích thông qua công thức:

$$(\mathbf{H}_n)_{ij} = \frac{1}{i+j-1} \quad (22)$$

Về mặt đại số, ma trận Hilbert là một ma trận đối xứng và xác định dương (*Symmetric Positive Definite* - SPD). Tuy nhiên, đặc tính đáng chú ý nhất của nó là các vectơ cột gần như phụ thuộc tuyến tính vào nhau khi kích thước n tăng lên. Điều này dẫn đến việc giá trị kỳ dị nhỏ nhất $\sigma_{\min}(\mathbf{H}_n)$ tiệm cận cực nhanh về 0. Hệ quả tất yếu là số điều kiện $\kappa(\mathbf{H}_n)$ bùng nổ theo hàm mũ (ví dụ với $n = 10$, $\kappa(\mathbf{H}_{10}) \approx 1.6 \times 10^{13}$), biến nó thành một bài toán thử thách khốc liệt cho bất kỳ thuật toán giải hệ phương trình nào [3, 8].




Figure 10: Sự gia tăng bùng nổ của số điều kiện $\kappa(\mathbf{A})$ theo kích thước n đối với ma trận Hilbert so với ma trận SPD.

3.5.2 Hiện tượng điển hình trên ma trận Hilbert

Khi tiến hành giải hệ phương trình với ma trận hệ số là ma trận Hilbert, chúng ta quan sát thấy ba hiện tượng số học vô cùng nghiêm trọng. Thứ nhất là sự khuếch đại sai số ở mức độ thảm họa. Bởi vì số điều kiện quá lớn, chỉ một lượng nhiễu cực nhỏ ở mức giới hạn độ chính xác của máy tính (ví dụ 10^{-16}) ở đầu vào cũng lập tức bị phóng đại thành sai số ở mức 10^{-3} hoặc lớn hơn ở kết quả đầu ra, phá hủy hoàn toàn độ tin cậy của nghiệm [3].

Thứ hai là hiện tượng triệt tiêu số (*catastrophic cancellation*). Trong các thuật toán dựa trên phép khử như khử Gauss, máy tính phải liên tục thực hiện các phép trừ giữa những số thập phân có giá trị rất gần nhau ($a \approx b$). Quá trình này làm mất đi hàng loạt các chữ số có nghĩa quan trọng, khiến cho thông tin thực sự của dữ liệu bị thay thế bởi rác máy tính (*numerical noise*) [3, 4].

Cuối cùng là sự lừa dối của phần dư. Một hiện tượng nguy hiểm và dễ gây nhầm lẫn trong tính toán số là việc **phần dư nhỏ hoàn toàn không đảm bảo nghiệm là chính xác** nếu hệ phương trình vốn dĩ là ill-conditioned. Sai số thực sự của nghiệm có thể rất lớn bất chấp $\|\mathbf{Ax} - \mathbf{b}\|_2 \approx 0$ [3].

3.5.3 Phân Tích Độ Tin Cậy Của Các Thuật Toán

Mỗi thuật toán thể hiện một mức độ chống chịu khác nhau trước tính chất ill-conditioned của ma trận Hilbert. Đối với phương pháp khử Gauss, mặc dù đã áp dụng chiến lược đổi dòng để chọn phần tử trội, các giá trị pivot sinh ra vẫn suy giảm nhanh chóng về các giá trị vô cùng nhỏ. Phép chia cho các pivot này làm tích lũy sai số khổng lồ, khiến nghiệm trả về hoàn toàn sai lệch [2]. Đối với phương pháp lặp Gauss-Seidel, do ma trận Hilbert không thỏa mãn điều kiện chéo trội nghiêm ngặt, dãy lặp mất đi động lực hội tụ. Trong thực nghiệm, cơ chế kiểm tra điều kiện hội tụ phát hiện hệ thống tiêu tốn hàng vạn vòng lặp mà không có tiến triển đáng kể, hoặc thậm chí phân kỳ [1].

Phương pháp phân rã QR sử dụng phép biến đổi Householder mang lại một chút cải thiện. Nhờ tính trực giao, nó giảm thiểu sự phát sinh thêm sai số số học trong quá trình tính toán. Dẫu vậy, bản chất ill-conditioned của ma trận gốc $\mathbf{H}_n$ vẫn chi phối hệ quả cuối cùng, khiến nghiệm của QR cũng không đạt được độ chính xác mong đợi [5].




Figure 11: Hành vi hội tụ của phương pháp Gauss-Seidel trên hai loại ma trận.

Trong tình huống bế tắc này, phương pháp Phân rã giá trị kỳ dị (SVD) nổi lên như giải pháp tối ưu và duy nhất có khả năng đối phó. Bằng cách tính toán nghiệm thông qua giả nghịch đảo Moore-Penrose:

$$\mathbf{x} = \mathbf{V}\mathbf{\Sigma}^+\mathbf{U}^T\mathbf{b} \quad (23)$$

thuật toán SVD cho phép chúng ta áp dụng một ngưỡng (*tolerance*) để chủ động loại bỏ các giá trị kỳ dị σ_i quá nhỏ (gần 0). Việc cắt tỉa này thực chất là loại bỏ các thành phần nhiễu đang khuếch đại sai số, giúp khôi phục lại tính ổn định cho nghiệm, biến SVD thành lựa chọn duy nhất mang lại kết quả đáng tin cậy [5, 2, 9].

3.6 Phân Tích Đánh Giá Trên Ma Trận Ngẫu Nhiên SPD (Well-conditioned)

3.6.1 Cơ Sở Toán Học và Đặc Điểm

Trái ngược với sự bất ổn của ma trận Hilbert, báo cáo cũng xem xét nhóm ma trận đối xứng xác định dương được thiết kế đặc biệt để có tính chất well-conditioned. Các ma trận này được sinh ngẫu nhiên nhưng kiểm soát chặt chẽ phổ giá trị riêng thông qua công thức:

$$\mathbf{A} = \mathbf{B}^T \mathbf{B} + \alpha \mathbf{I} \quad (24)$$

trong đó $\mathbf{B}$ là một ma trận ngẫu nhiên đều và $\alpha > 0$ là tham số điều chỉnh độ bù đường chéo (*diagonal shift*). Việc cộng thêm ma trận đường chéo $\alpha \mathbf{I}$ thực chất là tịnh tiến toàn bộ phổ giá trị riêng của hệ thống lên một lượng α . Điều này đảm bảo rằng tất cả các giá trị riêng đều lớn hơn hẳn 0, triệt tiêu hoàn toàn sự hiện diện của các thành phần kỳ dị. Nhờ đó, tỷ số giữa giá trị riêng cực đại và cực tiểu được giữ ở mức thấp (điển hình $\kappa(\mathbf{A}) \approx 10^1 \sim 10^3$), duy trì số điều kiện ở trạng thái lý tưởng, tạo ra một bài toán cực kỳ ổn định [5].

3.6.2 Phân Tích Độ Tin Cậy và Hiệu Năng Của Các Thuật Toán

Sự khác biệt về hiệu quả giữa các thuật toán trở nên hoàn toàn trái ngược khi áp dụng lên ma trận ngẫu nhiên SPD. Phương pháp khử Gauss tận dụng tối đa lợi thế của các phần tử trên đường chéo lớn. Quá trình chọn pivot diễn ra suôn sẻ, không gặp phải phép chia cho số nhỏ, dẫn đến nghiệm được giải mã với tốc độ chớp nhoáng và độ chính xác đạt đến giới hạn phần cứng ($\sim 10^{-16}$). Tương tự, phương pháp Gauss-Seidel tìm thấy môi trường hoàn hảo: tính xác định dương và các giá trị trên đường chéo đủ lớn đảm bảo cho dãy xấp xỉ thỏa mãn điều kiện hội tụ cực mạnh, hội tụ chỉ sau một số ít vòng lặp, đưa ra nghiệm xuất sắc trong thời gian ngắn nhất (như minh họa ở Hình 8).

Phương pháp phân rã QR vẫn duy trì phẩm chất ổn định tuyệt vời của mình, trả về nghiệm với sai số số học không đáng kể. Tuy nhiên, khi hệ thống vốn đã ổn định, sự phức tạp trong việc thiết lập các biến đổi Householder khiến nó tỏ ra chậm chạp hơn so với thuật toán Gauss thuần túy.

Đáng chú ý nhất là phương pháp SVD. Dù vẫn trả về nghiệm có độ chính xác hoàn hảo nhất, SVD lại bộc lộ nhược điểm trí mạng về chi phí tính toán (*computational cost*). Trong một bài toán well-conditioned, việc tính toán toàn bộ phổ giá trị kỳ dị là thừa thãi và vô cùng tốn kém

thời gian. Do đó, SVD không được khuyến nghị sử dụng thực tế cho lớp ma trận ngẫu nhiên này.

3.7 Tổng Kết Sự So Sánh

Bảng 6 tổng hợp lại một cách chi tiết những quan sát và đánh giá đối với hai trường hợp ma trận đã nghiên cứu (Ma trận Hilbert và Ma trận Ngẫu nhiên SPD). Qua đó có thể thấy rõ sự phụ thuộc mật thiết giữa bản chất của ma trận và hiệu năng của từng thuật toán giải số.

Table 6: Đối chiếu toàn diện đặc tính và kết quả giải số giữa hai họ ma trận

Tiêu chí đánh giá	Hệ Ma Trận Hilbert	Hệ Ma Trận Ngẫu nhiên SPD
Bản chất điều kiện	Ill-conditioned ($\kappa(\mathbf{A})$ khổng lồ)	Well-conditioned ($\kappa(\mathbf{A})$ nhỏ)
Khả năng kháng nhiễu	Cực kỳ mẫn cảm, mất mát thông tin	Ổn định, bảo toàn độ chính xác
Phần dư (<i>Residual</i>)	Nhỏ (gây ảo giác về độ chính xác)	Nhỏ và phản ánh đúng sai số thực
Phương pháp Gauss	Tích lũy sai số lớn, nghiệm sai lệch	Hoạt động hoàn hảo, tốc độ cao
Khả năng lặp (Seidel)	Phân kỳ hoặc trì trệ vô hạn	Hội tụ mạnh mẽ và nhanh chóng
Vai trò của SVD	Là giải pháp cứu cánh duy nhất	Quá tốn kém, không cần thiết

3.8 Phân Tích và Kết Luận

Thông qua việc khảo sát các hiện tượng trên, chúng ta có thể đúc kết được những nguyên lý cốt lõi, mang tính nền tảng cho lĩnh vực Đại số Tuyến tính Số (*Numerical Linear Algebra*).

Khác Biệt Giữa Tính Ổn Định Của Thuật Toán và Độ Chính Xác Của Nghiệm.

Một thuật toán được chứng minh là ổn định về mặt số học (như phân rã QR Householder) hoàn toàn không đảm bảo rằng nó sẽ luôn trả về một nghiệm chính xác. Thuật toán ổn định chỉ có nghĩa là nó không tự sinh ra thêm lượng sai số quá mức trong quá trình tính toán. Tuy nhiên, nếu bản thân bài toán vốn dĩ đã là ill-conditioned, bản chất toán học của hệ thống sẽ tự khuếch đại những sai số ban đầu, khiến mọi thuật toán dù tốt đến đâu cũng đành bất lực trong việc tìm ra nghiệm đúng [5, 3, 4].

Conditioning Là Đặc Tính Bền Vững. Số điều kiện là DNA của ma trận. Chúng ta không thể cải thiện sự tồi tệ của một bài toán ill-conditioned chỉ đơn thuần bằng cách thay thế thuật toán giải từ Gauss sang QR. Để đối phó với nó, bắt buộc phải can thiệp vào bản chất không gian số, chẳng hạn như sử dụng hệ thống số với độ chính xác cao hơn (*quadruple precision*), hoặc áp dụng các kỹ thuật chính quy hóa (*regularization*) như Tikhonov, hoặc sử dụng cơ chế cắt tỉa giá trị kỳ dị thông qua SVD để thiết lập lại một bài toán xấp xỉ nhưng ổn định hơn [2].

Sự Cần Thiết Của Đánh Giá Đa Chiều. Việc đánh giá sự thành công của một mô hình giải số không thể chỉ dừng lại ở chỉ số phần dư $\|\mathbf{Ax} - \mathbf{b}\|_2$. Đối với các hệ thống phức tạp, người kỹ sư bắt buộc phải trang bị các công cụ chẩn đoán bổ sung, bao gồm việc xấp xỉ số điều kiện $\kappa(\mathbf{A})$ và kiểm soát sai số tương đối (*relative error*) để tránh rơi vào cạm bẫy của những phần dư giả mạo [8].

Lựa Chọn Thuật Toán Phù Hợp. Không có một thuật toán nào là tối ưu cho mọi trường hợp. Khi ma trận đảm bảo tính xác định dương và ổn định, ưu tiên cao nhất là tốc độ, các phương pháp như Cholesky hay Gauss là lựa chọn hàng đầu. Khi đối mặt với hệ thống tổng quát có rủi ro tiềm ẩn, phương pháp phân rã QR đem lại sự an tâm về độ bền vững số học. Và cuối cùng, khi chạm trán với những bài toán ill-conditioned thực sự, SVD là công cụ giải phẫu duy nhất đủ khả năng cắt bỏ các thành phần nhiễu để cứu vãn hệ thống.

3.9 Kết Luận

Tóm lại, thực nghiệm với hai họ ma trận Hilbert và Ngẫu nhiên SPD đã phơi bày hai thái cực đối lập trong tính toán số học. Ma trận Hilbert là đại diện tiêu biểu cho sự sụp đổ của các phương pháp giải số truyền thống trước rào cản ill-conditioned, nơi mà chỉ có những công cụ phân tích sâu sắc như SVD mới có thể khôi phục lại trật tự. Ở chiều ngược lại, họ ma trận Ngẫu nhiên SPD được kiểm soát phổ chứng minh rằng một bài toán được thiết lập tốt (well-posed) sẽ là nền tảng để mọi thuật toán giải số có thể phô diễn tối đa tốc độ và sự chính xác của mình. Đồ thị thời gian cũng củng cố mạnh mẽ sự đánh đổi thiết yếu giữa độ phức tạp tính toán và độ tin cậy của nghiệm.

Trong thực tiễn tính toán khoa học, **chất lượng của bài toán được đặt ra luôn có tầm quan trọng vượt xa sự tinh vi của thuật toán được sử dụng để giải nó.** Nhiệm vụ quan trọng nhất không phải là tìm ra một thuật toán hoàn hảo cho một bài toán tồi, mà là nghệ thuật biến đổi (*preconditioning*) để đưa một bài toán tồi về trạng thái well-conditioned, nơi mà những thuật toán đơn giản nhất cũng có thể tỏa sáng [5].

4 Kết Luận và Bài Học

4.1 Tổng Kết Đồ Án

Qua quá trình thực hiện đồ án "Phép khử Gauss, Phân rã Ma trận và Phân tích Hiệu năng", nhóm chúng em đã đạt được những kết quả quan trọng sau:

- **Cài đặt thành công nền tảng Đại số tuyến tính:** Xây dựng hoàn chỉnh từ đầu (*from scratch*) các thuật toán cốt lõi bao gồm phép khử Gauss với Partial Pivoting, giải hệ phương trình (Back Substitution), tính định thức, ma trận nghịch đảo và tìm cơ sở không gian.
- **Hiểu sâu sắc về Phân rã ma trận:** Nắm vững và cài đặt thành công các phương pháp phân rã tiên tiến như QR (Gram-Schmidt, Householder) và SVD, cùng với việc chéo hóa ma trận. Các phương pháp này được củng cố mạnh mẽ về mặt trực quan thông qua video mô phỏng bằng thư viện **Manim**.
- **Phân tích độ ổn định số học:** Thông qua thực nghiệm đo đặc thời gian và sai số trên các ma trận đặc thù (ma trận đối xứng xác định dương - SPD và ma trận Hilbert), nhóm đã chứng minh được sự khác biệt giữa lý thuyết độ phức tạp $\mathcal{O}(n^3)$ và thời gian chạy thực tế, cũng như tác động tàn phá của sai số làm tròn đối với các ma trận có số điều kiện (*condition number*) lớn.

4.2 Những Khó Khăn Gặp Phải

Trong quá trình thực hiện đồ án, nhóm đã đối mặt với một số thách thức nhất định:

- **Sai số dấu phẩy động (Floating-point errors):** Khi làm việc với ma trận Hilbert ở kích thước lớn, các phương pháp phân rã bị tích lũy sai số nghiêm trọng. Điều này đòi hỏi nhóm phải nghiên cứu sâu về các kỹ thuật giảm thiểu sai số như Partial Pivoting và phép biến đổi Householder (thay vì Gram-Schmidt cổ điển).
- **Tối ưu hóa hiệu năng bằng Python:** Vì yêu cầu không sử dụng trực tiếp các hàm có sẵn của NumPy/SciPy cho cốt lõi thuật toán, việc đảm bảo thời gian chạy hợp lý cho ma trận kích thước lớn ($n \geq 500$) đòi hỏi code thuần Python phải được vector hóa tối đa trong giới hạn cho phép.
- **Trực quan hóa với Manim:** Đây là một thư viện mạnh mẽ, có khả năng trực quan hóa các bài toán một cách rõ ràng, dễ hiểu và đẹp mắt. Tuy nhiên, để làm được một

video hoàn chỉnh, nhóm đã phải bỏ rất nhiều thời gian để nghiên cứu hướng dẫn từ kênh 3Blue1Brown¹.

4.3 Bài Học Rút Ra

1. **Sự khác biệt giữa Lý thuyết và Thực hành:** Một thuật toán đúng về mặt toán học (như khử Gauss cơ bản) chưa chắc đã sử dụng được trong thực tế nếu không có kỹ thuật pivoting để đối phó với độ chính xác hữu hạn của máy tính.
2. **Tầm quan trọng của Condition Number:** Ma trận Hilbert là một "bài test" kinh điển giúp nhóm thấm nhuần khái niệm *ill-conditioned*. Mọi phép toán trên nó đều rất nhạy cảm, giúp nhóm trân trọng giá trị của phân rã SVD trong việc chẩn đoán hệ thống.
3. **Kỹ năng làm việc nhóm và Quản lý mã nguồn:** Việc chia nhỏ các module, sử dụng Git/GitHub để quản lý tiến độ, cùng với LaTeX để tổng hợp báo cáo đã giúp nhóm nâng cao kỹ năng làm việc cộng tác trong môi trường kỹ thuật phần mềm thực thụ.

¹3Blue1Brown là kênh YouTube nổi tiếng về toán học trực quan do Grant Sanderson sáng lập. Anh cũng chính là tác giả đã tạo ra thư viện Manim.



5 Phân Công Công Việc

Đồ án được chia thành các phần hành cụ thể và được phối hợp thực hiện bởi tất cả các thành viên trong nhóm. Bảng dưới đây tóm tắt vai trò và đóng góp của từng thành viên:

Thành viên & MSSV	Vai trò	Tỷ lệ hoàn thành
Khang Phuc Nguyen (24120068) - Chịu trách nhiệm quản lý, và phân công công việc cho các thành viên - Thiết kế kiến trúc code tổng thể (Project Architecture) - Hoàn tất báo cáo tổng quan của toàn bộ đồ án - Đảm bảo chất lượng báo cáo LaTeX từng phần, rà soát code của từng người (Reviewer & Editor) - Làm video Manim của Phần 2. - Cài đặt Gauss-Elimination	Leader	100%
Nghia Trong Hoang (24120103) - Phần 1: Cài đặt hàm tìm hạng (rank), cơ sở không gian dòng/cột. - Viết báo cáo lý thuyết cho Phần 1. - Phần 3: Thực hiện phân tích, đưa ra nhận xét và viết Kết luận phần 1.	Member	100%
Nhat Hoang Mai (24120109) - Phần 1: Cài đặt tính $\det(A)$ bằng phép khử Gauss. - Phần 2: Phụ trách viết lý thuyết cho phân rã SVD và QR, vẽ hình TikZ minh họa. - Phần 3: Cài đặt thuật toán các phương pháp lặp.	Member	100%
Nhat Hoang Nguyen (24120110) - Phần 1: Cài đặt <code>back_substitution</code> và khung chính <code>gaussian.py</code>. - Phần 2: Xây dựng code kiểm chứng các thuật toán phân rã QR và SVD (<code>verify.py</code>). - Phần 3: Lập trình kịch bản chạy thực nghiệm (<code>benchmark.py</code>).	Member	100%
Long Nhat Phung Vo (24120088) - Phần 1: Cài đặt thuật toán tìm ma trận nghịch đảo (inverse). - Phần 2: Cài đặt trực tiếp (from scratch) thuật toán phân rã QR và SVD. - Phần 3: Phân tích tính ổn định số của các phương pháp.	Member	100%

Table 7: Bảng phân công công việc và đánh giá mức độ hoàn thành

References

- [1] G. Strang, *Introduction to Linear Algebra*, 6th ed. Wellesley-Cambridge Press, 2023.
- [2] G. H. Golub and C. F. V. Loan, *Matrix Computations*, 4th ed. Johns Hopkins University Press, 2013.
- [3] N. J. Higham, *Accuracy and Stability of Numerical Algorithms*, 2nd ed. SIAM, 2002.
- [4] J. H. Wilkinson, *The Algebraic Eigenvalue Problem*. Clarendon Press, 1965.
- [5] L. N. Trefethen and D. B. III, *Numerical Linear Algebra*. SIAM, 1997.
- [6] Y. Saad, *Iterative Methods for Sparse Linear Systems*, 2nd ed. SIAM, 2003.
- [7] R. L. Burden, J. D. Faires, and A. M. Burden, *Numerical Analysis*, 10th ed. Cengage Learning, 2015.
- [8] J. W. Demmel, *Applied Numerical Linear Algebra*. SIAM, 1997.
- [9] P. C. Hansen, "The truncated svd as a method for regularization," *BIT Numerical Mathematics*, vol. 27, no. 4, pp. 534–553, 1987.